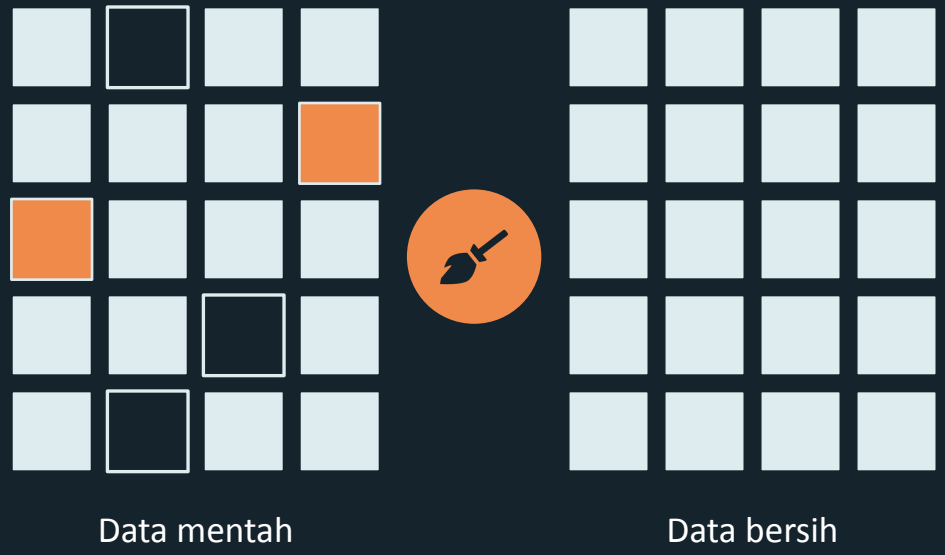
PERTEMUAN 2 · DATA SCIENCE

Preprocessing Data 1

Data cleaning: membuat data layak dipercaya



PEMBUKA

Peta belajar hari ini

1. **Kenapa perlu bersih** — Data kotor, keputusan keliru
2. **Kualitas data** — Empat dimensi
3. **Nilai kosong** — Buang atau isi?
4. **Duplikat & format** — Satu data, satu cara tulis
5. **Outlier** — Kesalahan atau nyata?
6. **Praktik** — Bersihkan data pelanggan

Hasil akhir hari ini: data pelanggan yang bersih dan laporan “sebelum vs sesudah” untuk manajer.

KENAPA DATA CLEANING

Data kotor, keputusan keliru



AKIBATNYA DI PERUSAHAAN

Laporan menyesatkan

Jumlah pelanggan terlihat lebih banyak dari kenyataan

Kampanye salah sasaran

Promo yang sama terkirim dua kali ke orang yang sama

Model keliru belajar

Model meniru pola dari data yang salah

KUALITAS DATA

Empat dimensi kualitas data



Lengkap

Adakah yang kosong?

CONTOH

Pendapatan pelanggan tidak diisi



Valid

Masuk akalkah nilainya?

CONTOH

Umur pelanggan 121 tahun



Konsisten

Samakah cara penulisannya?

CONTOH

“Jakarta”, “JKT”, dan “jakarta”



Unik

Adakah yang tercatat dua kali?

CONTOH

Satu pelanggan terdaftar dengan dua ID

KUALITAS DATA

Kenali dulu, bersihkan kemudian

`head()` `sample()`

Seperti apa isinya?

`info()`

Tipe tiap kolom sesuai isinya?

`isnull().sum()`

Adakah yang kosong?

`describe()`

Min dan max masuk akal?

`value_counts()`

Adakah label aneh atau bersinonim?

`nunique()`

Kolom mana yang selalu berbeda?

`hist()` `boxplot()`

Adakah nilai yang menyendiri?

`duplicated()`

Adakah yang tercatat dua kali?

Catat setiap keanehan di tabel temuan: kolom apa, anehnya di mana, dimensi apa, dan rencana tindakannya

Tujuh langkah membersihkan data

Sebelum mulai: simpan data asli, kerjakan semua langkah pada salinannya

1	2	3	4	5	6	7
Audit	**Tipe data**	**Kolom tak berguna**	**Duplikat**	**Kategori**	**Nilai janggal & outlier**	**Nilai kosong**
Periksa empat dimensi	Teks jadi tanggal atau angka	Isinya sama semua	Termasuk yang beda ID	Satukan label yang sama arti	Salah atau nyata?	Buang atau isi

Sepanjang proses: catat setiap keputusan dan alasannya di log pembersihan

KUALITAS DATA

Tipe data yang tepat

KOLOM	TERBACA SEBAGAI	SEHARUSNYA	KENAPA PENTING
`Dt_Customer`	Teks	Tanggal	Agar bisa diurutkan dan dihitung selisihnya
`ID`	Angka	Label	Tidak bermakna jika dijumlah atau dirata-rata
`Response`	Angka 0 / 1	Kategori ya / tidak	1 berarti pelanggan merespons kampanye
`Income`	Angka desimal	Angka	Sudah tepat

`04-09-2012`

4 September atau 9 April? Jangan biarkan komputer menebak. Tulis formatnya: `format="%d-%m-%Y"`

Nilai kosong: buang atau isi?

KENAPA BISA KOSONG?



Tidak diisi

Pelanggan melewati kolom isian



Gangguan sistem

Data hilang saat dipindahkan



Memang tidak ada

Misalnya belum pernah berbelanja

PILIHAN DAN KAPAN COCOK

Buang baris

Yang kosong sedikit dan barisnya tidak penting

Buang kolom

Sebagian besar isi kolom kosong

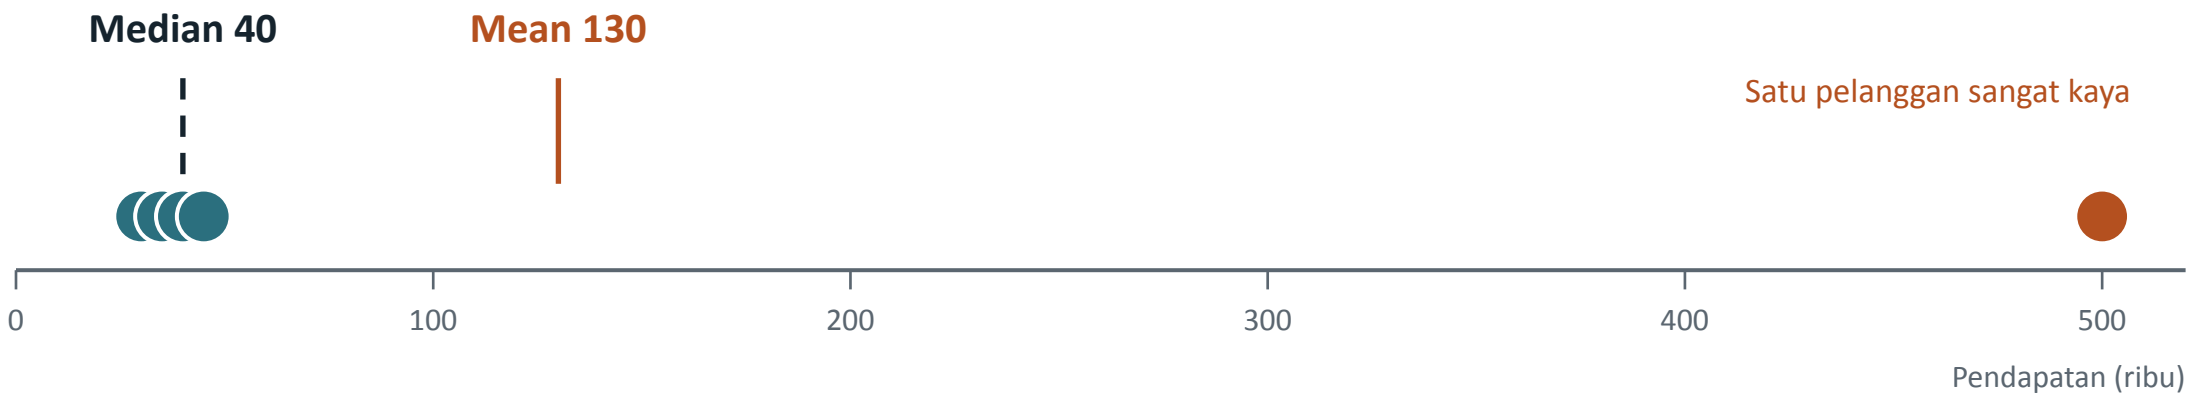
Isi median / modus

Yang kosong sedikit, tetapi barisnya berharga

Isi per kelompok

Nilainya jelas berbeda antar kelompok

Mean atau median?



Mean

130 ribu

Tertarik oleh satu nilai ekstrem

Median

40 ribu

Tetap mewakili pelanggan pada umumnya

Contoh ilustrasi: pendapatan lima pelanggan (30, 35, 40, 45, dan 500 ribu).

Duplikat: yang terlihat dan yang bersembunyi

Duplikat persis

Semua kolom sama, termasuk ID

ID	Tahun lahir	Pendapatan	Belanja
1001	1975	58.000	640
1001	1975	58.000	640

```
df.duplicated()
```

Duplikat tersembunyi

Semua kolom sama, kecuali ID

ID	Tahun lahir	Pendapatan	Belanja
1001	1975	58.000	640
2087	1975	58.000	640

```
df.duplicated(subset=kolom_tanpa_id)
```

Contoh ilustrasi. Pertanyaan kunci: mungkinkah dua orang berbeda sama persis di semua kolom?

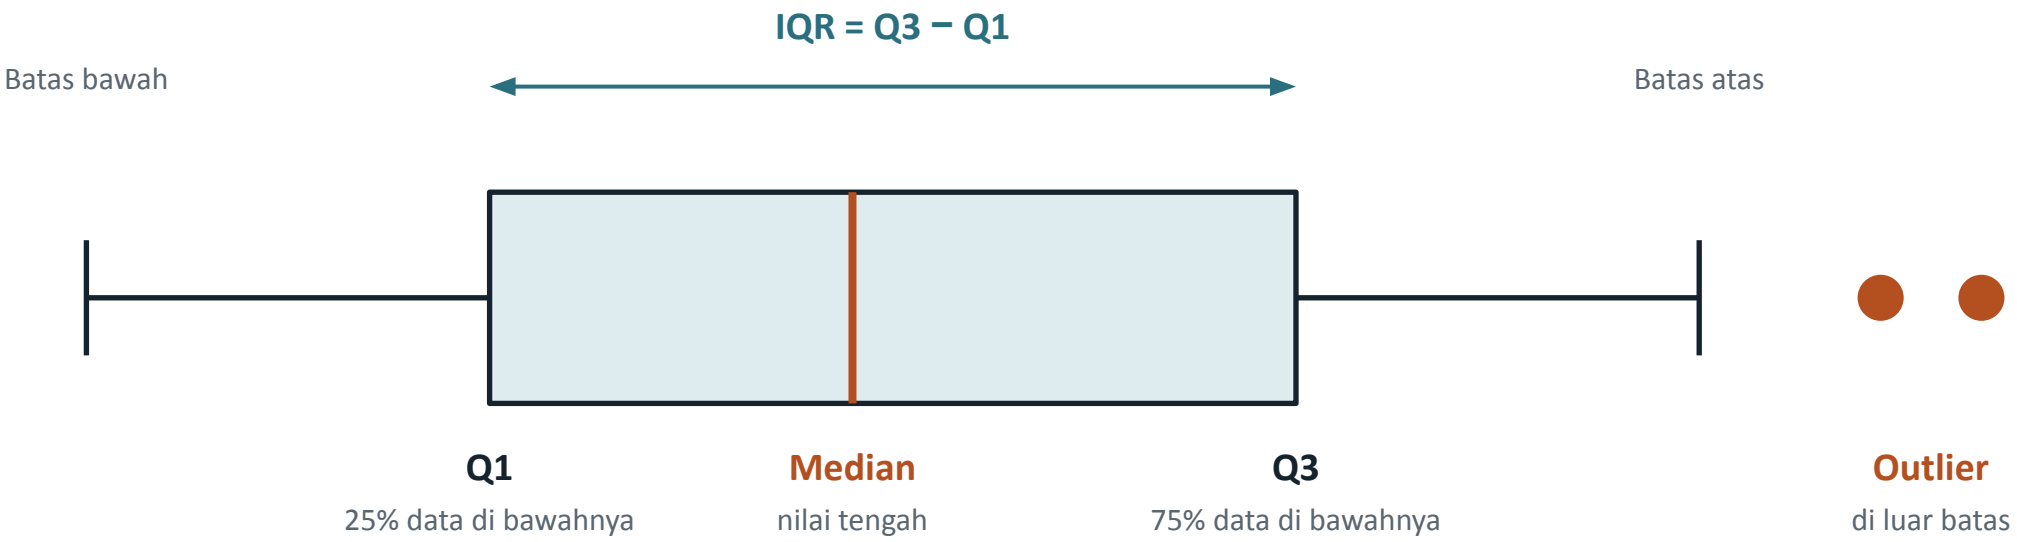
FORMAT

Satu arti, satu cara penulisan

Huruf besar-kecil & singkatan	`Jakarta` `JKT` `jakarta`	→ `Jakarta`
Sinonim	`Pria` `L` `Laki-laki`	→ `Laki-laki`
Format tanggal	`04-09-2012` `2012/09/04`	→ `2012-09-04`
Satuan	`1,5 kg` `1500 gram`	→ `1500 gram`

Alat di pandas: `replace()` `str.lower()` `str.strip()` `pd.to_datetime()`

Menemukan outlier dengan IQR

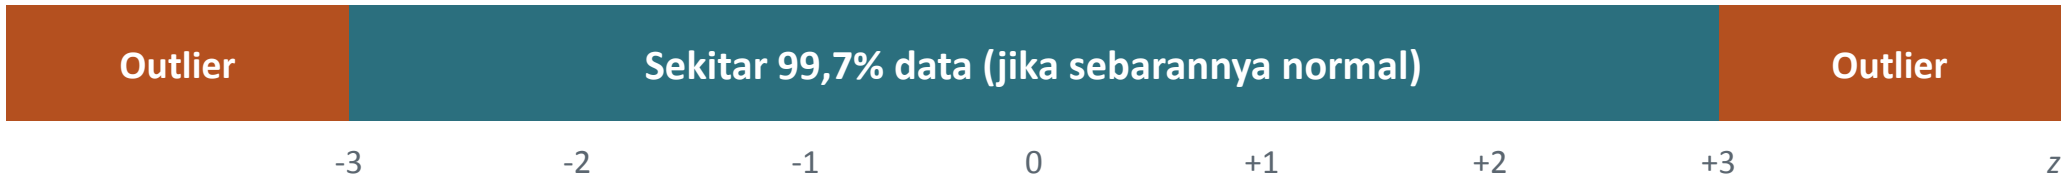


Batas bawah $Q1 - 1{,}5 \times IQR$

Batas atas $Q3 + 1{,}5 \times IQR$

Menemukan outlier dengan z-score

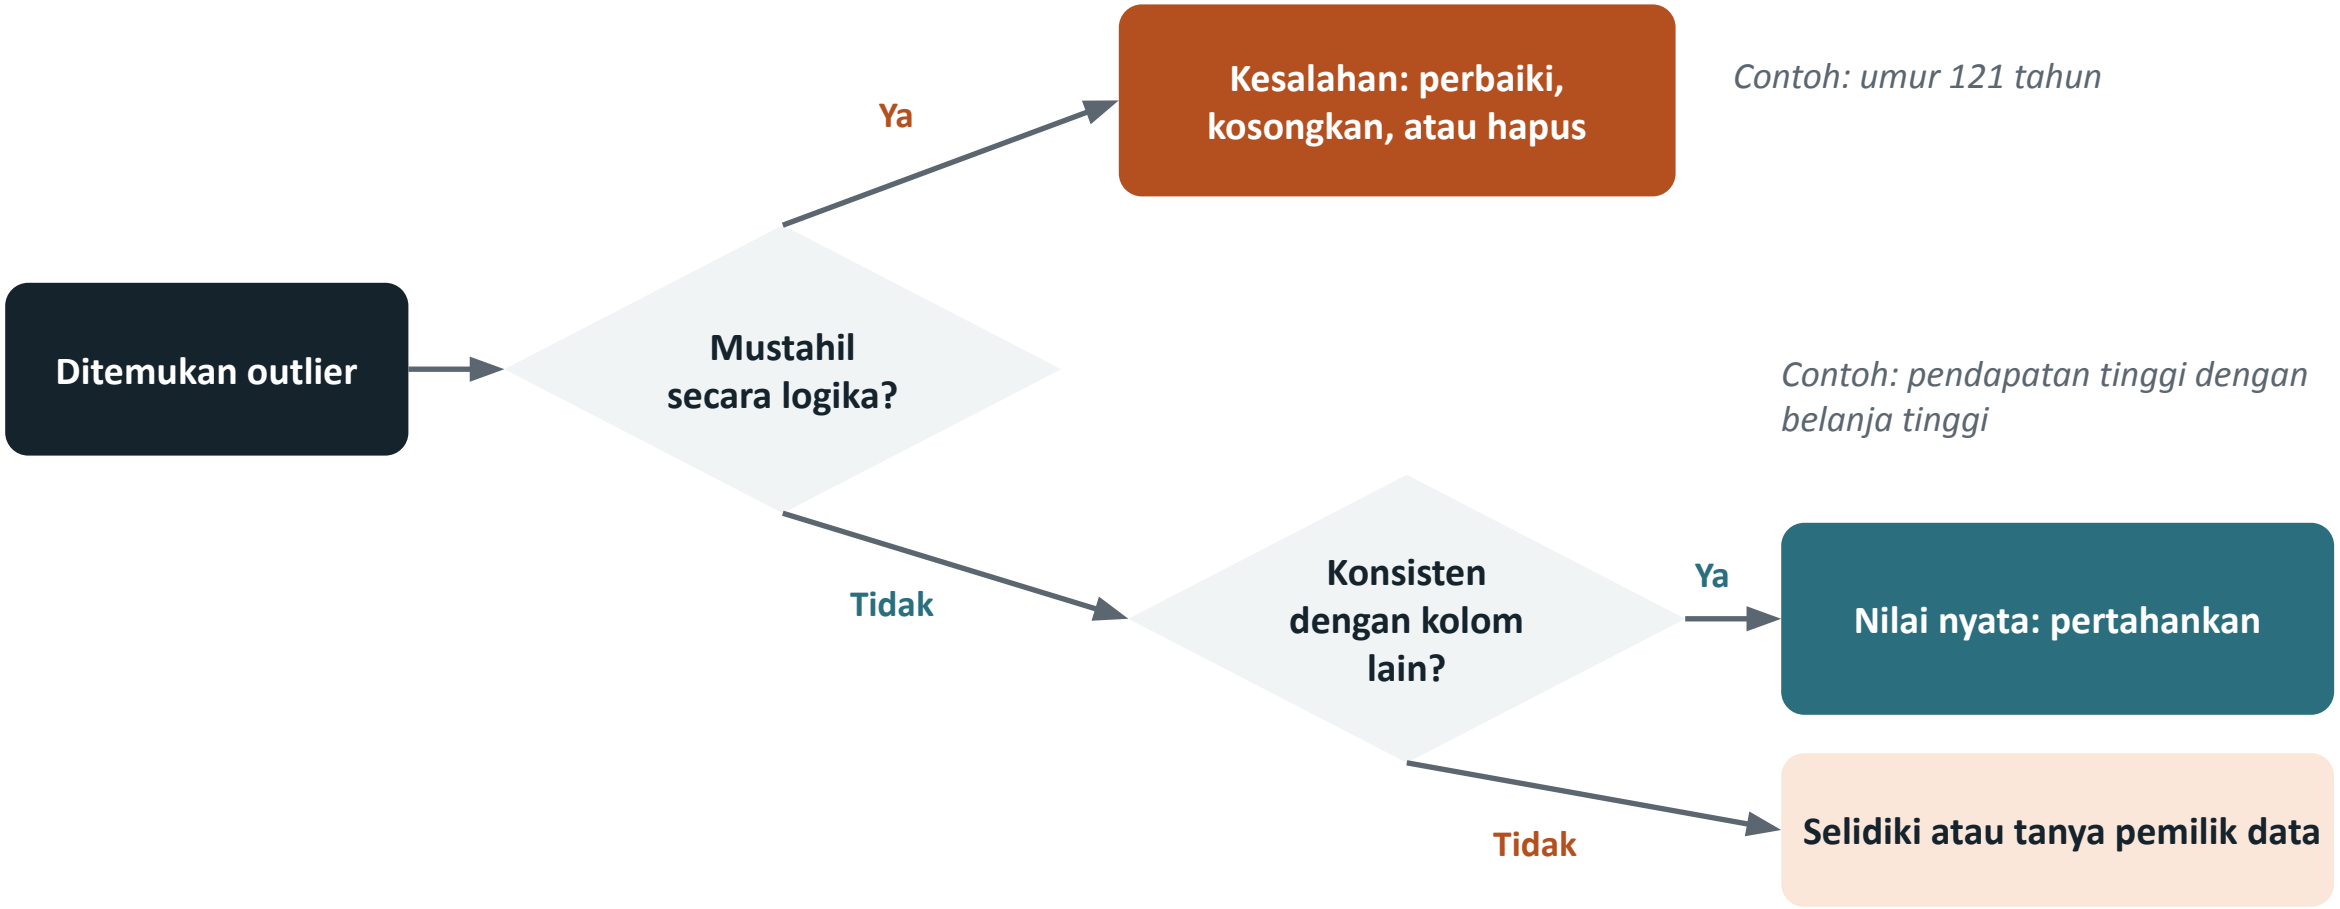
```
z = (nilai – rata-rata) / simpangan baku
```



IQR — Tidak terpengaruh nilai ekstrem; cocok untuk sebaran yang miring

Z-score — Mudah dihitung; paling cocok jika sebaran mendekati normal

Outlier belum tentu kesalahan



BUSINESS CASE

Laporan profil yang janggal

Laporan anak magang (dari data mentah)

2.240 pelanggan

18–121 tahun umurnya

8 jenis status pernikahan

> **Umur 121 tahun? Status pernikahan ada delapan? Tolong cek data ini sebelum saya bawa ke direksi besok.**

Manajer marketing RetailKu

Waktu dalam cerita

Juli 2014

Peranmu

Data analyst di tim marketing

BUSINESS CASE

Dari pertanyaan bisnis ke pertanyaan data

PERTANYAAN BISNIS	PERTANYAAN DATA	
Berapa jumlah pelanggan kita sebenarnya?	Adakah pelanggan yang tercatat lebih dari sekali?	Unik
Benarkah ada yang berumur 121 tahun?	Nilai mana yang tidak masuk akal?	Valid
Bisakah angka pendapatan dipercaya?	Adakah nilai kosong atau nilai ekstrem?	Lengkap
Kenapa status pernikahan ada delapan?	Adakah label yang tidak konsisten atau tidak valid?	Konsisten

BUSINESS CASE

Kenalan dengan datanya

2.240

baris, satu baris satu pelanggan

29

kolom

2012–2014

rentang tanggal pelanggan mendaftar

P2–P7

dipakai sampai Pertemuan 7



Awas jebakan: nama file-nya .csv, tetapi kolomnya dipisahkan tab, bukan koma. Bacanya dengan `sep="\t"`

Sumber: Kaggle, Customer Personality Analysis (Akash Patel). Penjelasan tiap kolom ada di README.md.

BUSINESS CASE

Empat kelompok kolom

Profil

Siapa pelanggannya?

- ID
- Year_Birth
- Education
- Marital_Status
- Income
- Kidhome
- Teenhome
- Dt_Customer
- Recency
- Complain

Produk

Apa yang dibeli? (2 tahun)

- MntWines
- MntFruits
- MntMeatProducts
- MntFishProducts
- MntSweetProducts
- MntGoldProds

Promosi

Bagaimana responsnya?

- NumDealsPurchases
- AcceptedCmp1 – 5
- Response

Kanal

Belanja lewat mana?

- NumWebPurchases
- NumCatalogPurchases
- NumStorePurchases
- NumWebVisitsMonth

Ditambah dua kolom yang isinya sama di semua baris: Z_CostContact dan Z_Revenue.

PRAKTIK

Alur praktik di Google Colab

1 Muat data	2 Audit	3 Bersihkan	4 Laporkan	5 Simpan
Hati-hati jebakan pemisah tab	Empat dimensi kualitas	Tujuh langkah, semua dicatat	Sebelum vs sesudah	Data bersih untuk P3

TIGA ATURAN SELAMA PRAKTIK



Jangan ubah data asli. Kerjakan pada salinan



Ragu? Selidiki dulu, jangan langsung hapus



Catat setiap keputusan di log

PENUTUP

Rangkuman



Periksa sebelum membersihkan

Audit empat dimensi: lengkap, valid, konsisten, unik



Data asli tidak disentuh

Bekerja pada salinan agar selalu bisa mengulang



Outlier belum tentu salah

Selidiki dulu; nilai nyata dipertahankan



Catat setiap keputusan

Log pembersihan membuat hasilmu bisa dipercaya