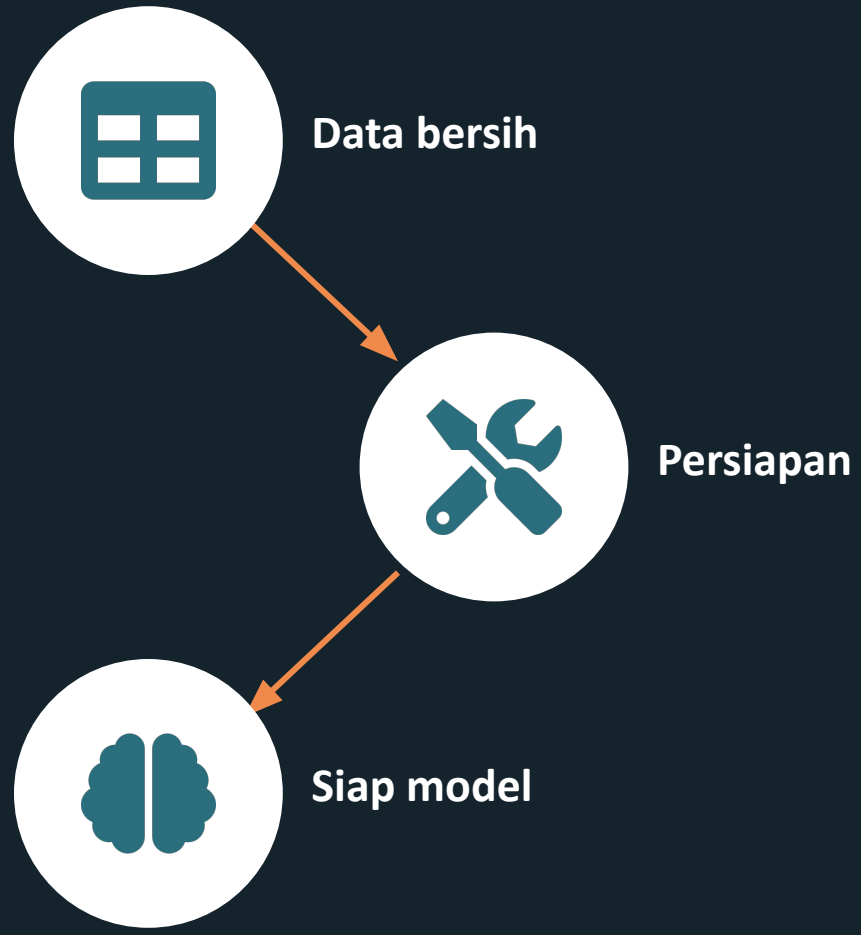
PERTEMUAN 3 · DATA SCIENCE

Preprocessing Data 2

Feature engineering dan menyiapkan data untuk model



PEMBUKA

Peta belajar hari ini



Hasil akhir hari ini: tabel siap model dan pipeline yang bisa dipakai untuk pelanggan baru.

SIAP MODEL?

Bersih belum tentu siap model



Semua berupa angka

Model tidak bisa menghitung dengan “PhD” atau sebuah tanggal

Encoding



Skalanya setara

Pendapatan puluhan ribu, jumlah anak hanya 0 sampai 3

Scaling



Fiturnya bermakna

Informasi penting tersebar di banyak kolom

Feature engineering



Tanpa bocoran

Model diuji dengan data yang belum pernah ia lihat

Split & pipeline

FEATURE ENGINEERING

Meracik kolom menjadi fitur

KOLOM ASLI	FITUR BARU	ARTI BAGI BISNIS
`2014 − Year_Birth`	**Age**	Umur pelanggan
`1 Jul 2014 − Dt_Customer`	**Tenure_days**	Lama menjadi pelanggan
`Kidhome + Teenhome`	**Children**	Jumlah anak di rumah
`Jumlah 6 kolom Mnt…`	**TotalSpend**	Nilai belanja selama 2 tahun
`TotalSpend ÷ TotalPurchases`	**AvgSpendPerPurchase**	Belanja rata-rata per transaksi

Uji sederhana fitur yang baik: bisakah artinya dijelaskan dalam satu kalimat kepada tim marketing?

FEATURE ENGINEERING

Empat cara membuat fitur baru



Dari tanggal

Umur, lama berlangganan, hari dalam seminggu

```
Age = 2014 − Year_Birth
```



Agregasi

Menjumlahkan kolom yang sejenis

```
Children = Kidhome + Teenhome
```



Rasio

Membandingkan dua besaran

```
Belanja ÷ jumlah transaksi
```

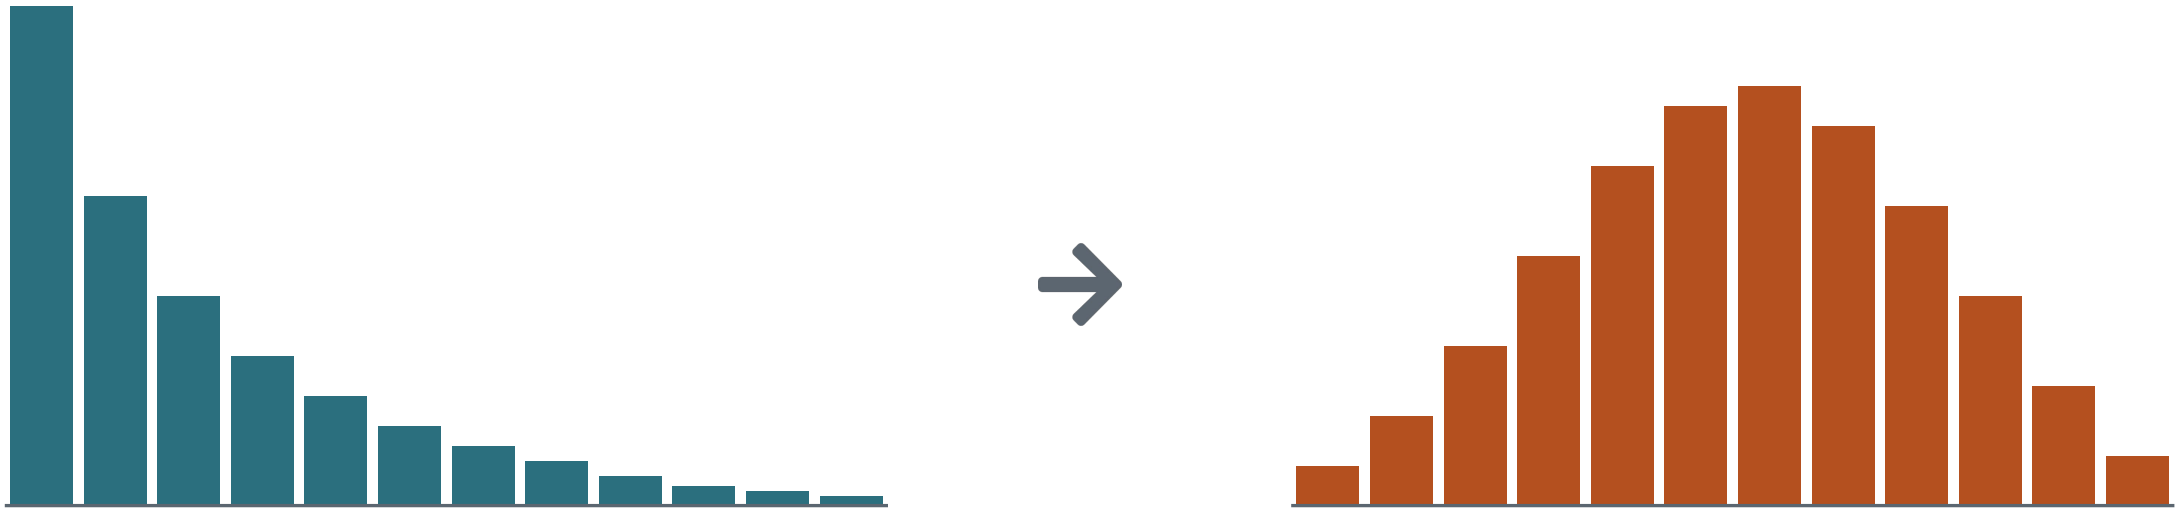


Binning

Mengelompokkan angka menjadi rentang

```
Umur 37 → "31-45"
```

Transformasi log untuk sebaran miring



Sebelum: menumpuk di kiri, ekor panjang

Sesudah log: lebih seimbang

```
np.log1p(x)  =  log(1 + x)
```

Aman untuk nilai 0. Ilustrasi bentuk sebaran, bukan data asli.

Tiga cara mengubah kategori menjadi angka

Label encoding

Beri nomor urut berdasarkan abjad

```
Divorced → 0
Married → 1
Single → 2
```

Berisiko: menciptakan urutan palsu

Ordinal encoding

Kategori yang punya urutan

```
Basic → 0
Graduation → 1
Master → 2
PhD → 3
```

Urutan ditentukan sendiri, bukan abjad

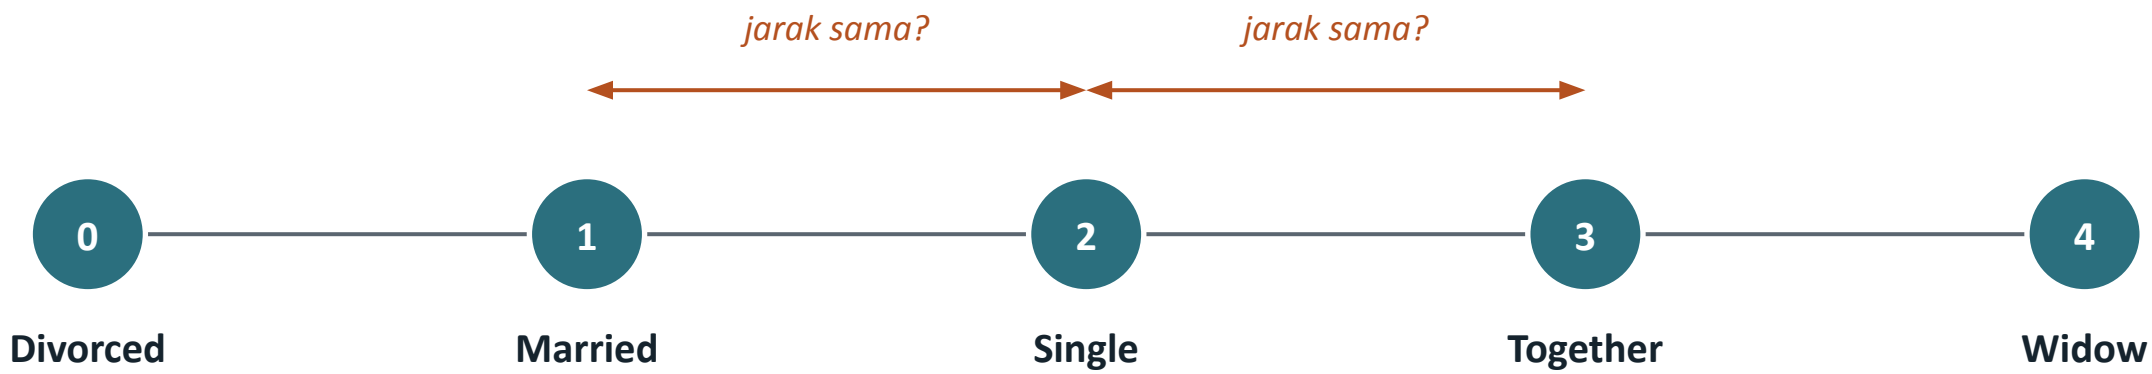
One-hot encoding

Kategori tanpa urutan

```
Married → 0 1 0 0 0
Single  → 0 0 1 0 0
```

Satu kolom 0/1 untuk tiap kategori

Jebakan label encoding



Widow (4) “lebih besar” dari Married (1)?

Status pernikahan tidak punya urutan

Married ke Single sama jauhnya dengan Single ke Together?

Jarak antar status tidak bisa dihitung

One-hot encoding: satu kolom per kategori

Marital_Status
Married
Single
Together
Widow



Divorced	Married	Single	Together	Widow
0	**1**	0	0	0
0	0	**1**	0	0
0	0	0	**1**	0
0	0	0	0	**1**

Tepat satu angka 1

di setiap baris

`drop_first=True`

membuang satu kolom yang bisa ditebak

Kategori sangat banyak?

jumlah kolom membengkak

SCALING

Kenapa skala perlu disetarakan?

Siapa yang paling mirip dengan A?

A

Pendapatan 50.000

Anak 0

B

Pendapatan 51.000

Anak 3

C

Pendapatan 60.000

Anak 0

Tanpa scaling

```
Jarak A–B 1.000
Jarak A–C 10.000
```

Paling mirip: B

Setelah standardisasi

```
Jarak A–B 4,01
Jarak A–C 0,46
```

Paling mirip: C

Kolom berangka besar mendominasi. Model yang menghitung jarak, seperti K-Means di Pertemuan 4, akan hampir hanya memperhatikan pendapatan dan mengabaikan jumlah anak.

Standardization atau min-max?

Standardization

`StandardScaler`

```
(x − rata-rata) / simpangan baku
```



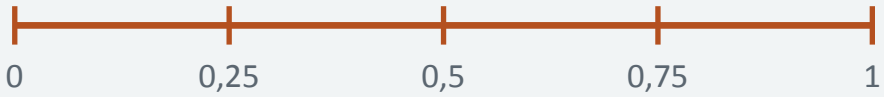
Rata-rata 0, simpangan baku 1

Pilihan umum; tidak membatasi rentang

Min-max scaling

`MinMaxScaler`

```
(x − min) / (max − min)
```



Semua nilai di antara 0 dan 1

Rentang pasti; peka terhadap nilai ekstrem

Data latih dan data uji

Data latih · 1.640 pelanggan

80% · untuk belajar · 15,2% merespons

Data uji · 411

20% · untuk ujian
15,1% merespons

Seperti ujian: soal ujian tidak boleh sama dengan soal latihan.

`stratify=y` menjaga persentase yang merespons sama di kedua bagian.

```
train_test_split(X, y, test_size=0.2, stratify=y, random_state=42)
```

Kebocoran data: nilai bagus yang palsu



Seperti bocoran soal ujian: nilainya tinggi, padahal tidak paham. Begitu menghadapi soal baru, gagal.

1 Target masuk ke fitur

Fitur yang dihitung dari jawaban yang ingin diprediksi

CONTOH

Total kampanye diterima termasuk kampanye terakhir

2 Data uji ikut dipelajari

Median, rata-rata, atau batas kelompok dihitung dari seluruh data

CONTOH

Scaler di-fit sebelum data dibagi

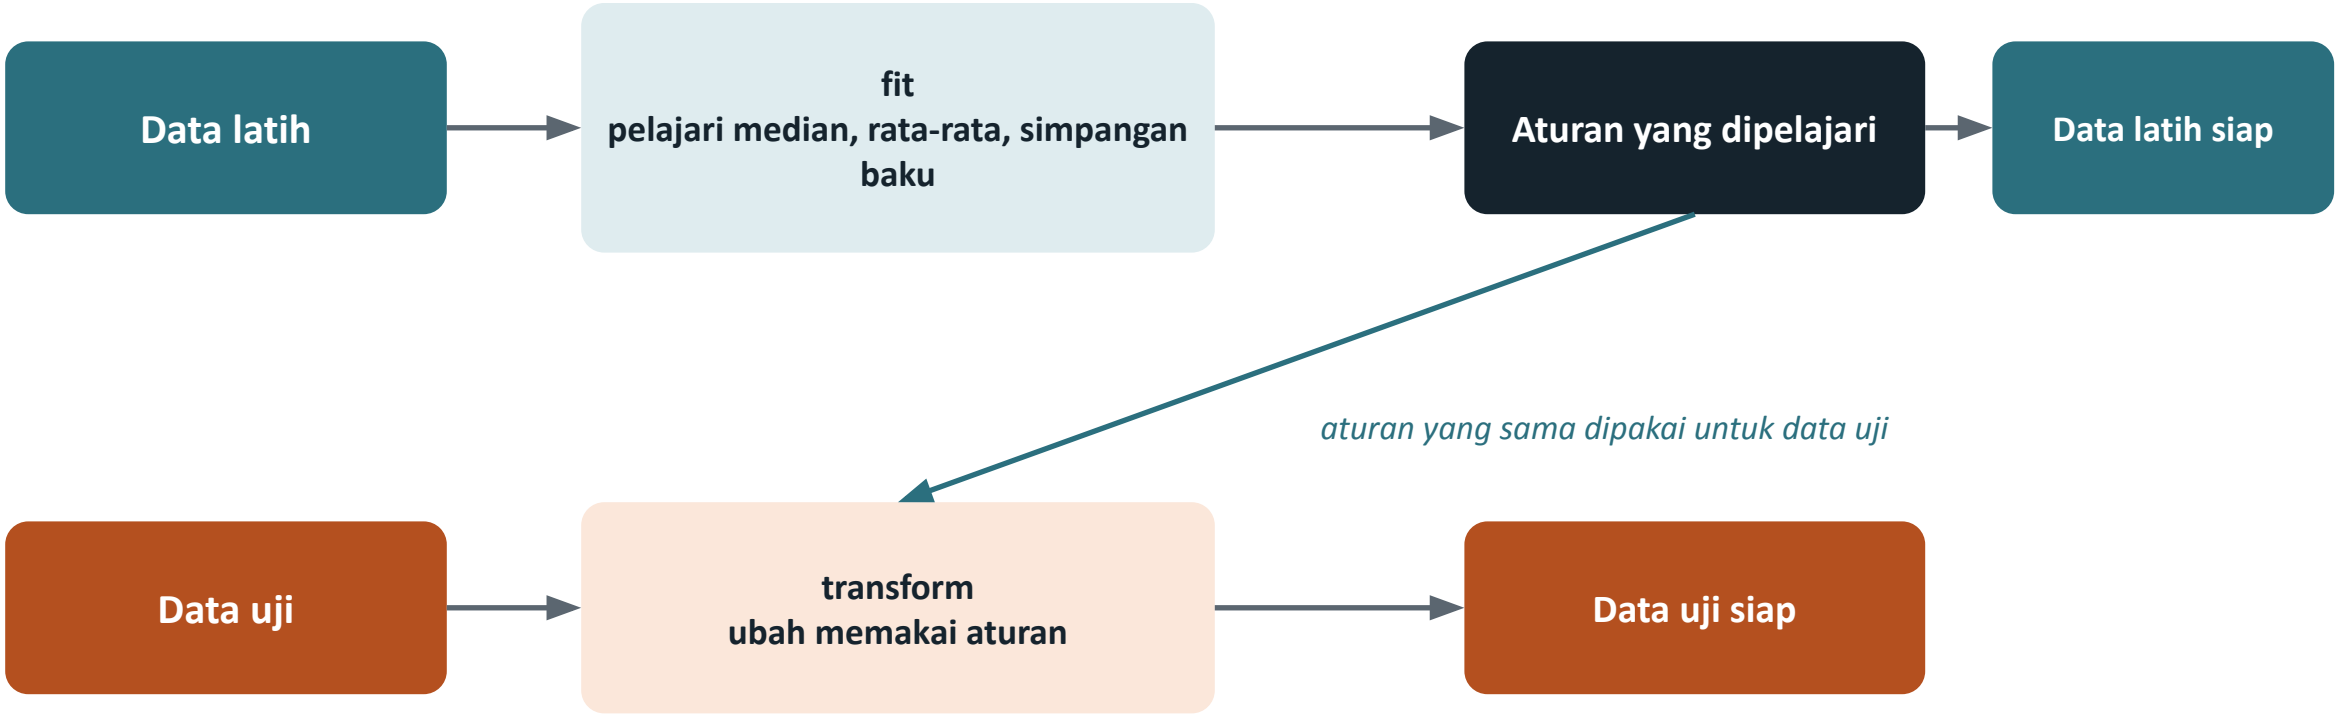
3 Data kembar di latih dan uji

Model “menebak” data yang sudah ia hafal

CONTOH

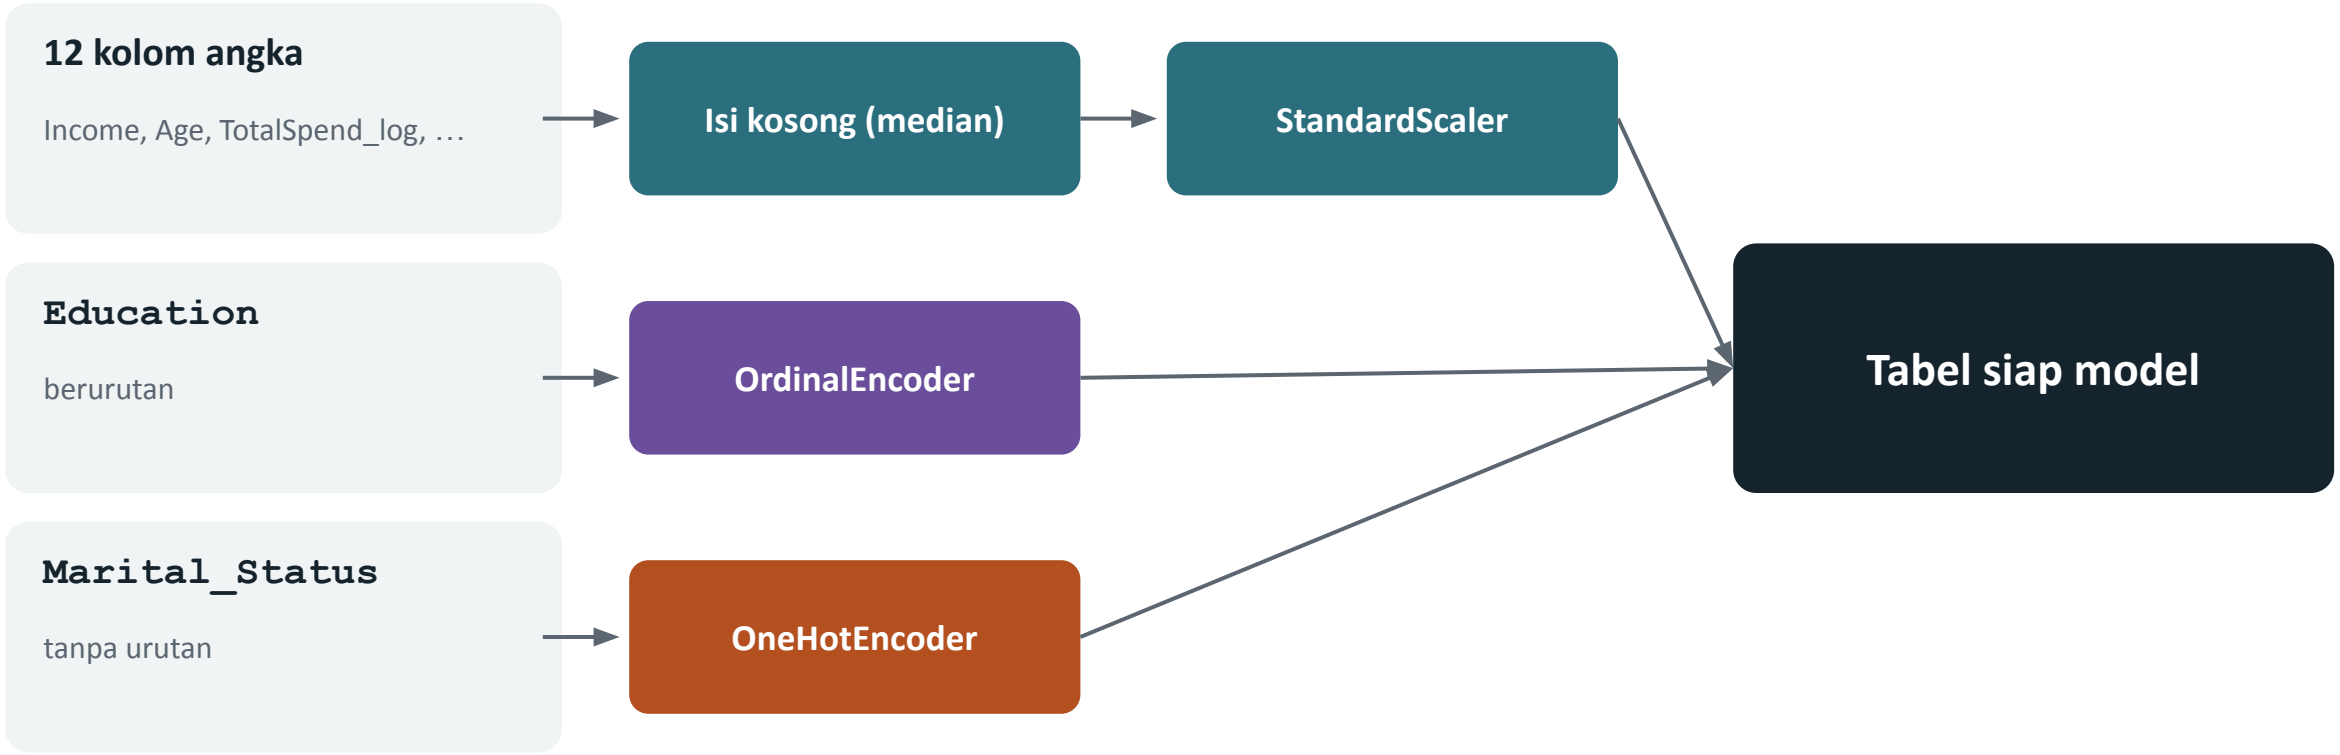
Pelanggan tercatat dua kali

Aturan emas: fit hanya di data latih



Jangan pernah: fit pada data uji, atau fit pada seluruh data sebelum dibagi.

Pipeline: semua langkah dalam satu alur




```
persiapan.fit_transform(X_train)   →   persiapan.transform(X_test)
```

BUSINESS CASE

Permintaan dari data scientist senior

Tolong kirimkan tabel siap model: semua kolom berupa angka, skalanya setara, dan tanpa informasi yang bocor. Buat juga prosesnya bisa diulang untuk pelanggan baru.

Data scientist senior RetailKu

Kampanye ke-7

Disetujui direksi, asal lebih tepat sasaran

Pertemuan 4

Mengelompokkan pelanggan menjadi segmen

Pertemuan 5

Memprediksi siapa yang akan merespons

Waktu dalam cerita: Juli 2014 · Peranmu: data analyst di tim marketing RetailKu (perusahaan fiktif)

BUSINESS CASE

Dari pertanyaan bisnis ke teknik

PERTANYAAN BISNIS	PERTANYAAN DATA	
Apa yang menggambarkan seorang pelanggan?	Fitur baru apa yang bisa dibuat?	**Fitur**
Bagaimana model membaca “PhD”?	Bagaimana mengubah kategori menjadi angka?	**Encoding**
Pendapatan vs jumlah anak, setara?	Bagaimana menyetarakan skala?	**Scaling**
Bagaimana menguji model dengan adil?	Bagaimana membagi data dan mencegah bocoran?	**Split**
Bagaimana jika ada pelanggan baru?	Bagaimana membuat semua langkah bisa diulang?	**Pipeline**

PRAKTIK

Alur praktik di Google Colab

1 Bersihkan ulang	2 Eksplorasi	3 Fitur baru	4 Encoding & scaling	5 Split & pipeline
Fungsi dari Pertemuan 2	Apa yang belum siap?	Umur, total belanja, rasio	Kategori dan skala	Tanpa bocoran

TIGA ATURAN SELAMA PRAKTIK



Fit hanya di data latih



Beri nama fitur yang dimengerti orang bisnis



Bungkus langkah dalam fungsi agar bisa diulang

PENUTUP

Rangkuman



Fitur yang baik bisa dijelaskan

Umur, total belanja, lama berlangganan



Urutan menentukan encoding

Berurutan: ordinal. Tanpa urutan: one-hot



Skala harus setara

Agar kolom berangka besar tidak mendominasi



Fit hanya di data latih

Pipeline menjaga aturan ini secara otomatis

PENUTUP

Tugas dan pertemuan berikutnya

TUGAS

1. Lengkapi kamus fitur untuk minimal 6 fitur baru, dalam bahasa yang dimengerti tim marketing

2. Tulis 3–4 kalimat: bagaimana kamu memastikan tidak ada kebocoran data

PERTEMUAN 4

Unsupervised Learning

Business case: siapa saja pelanggan kita?

