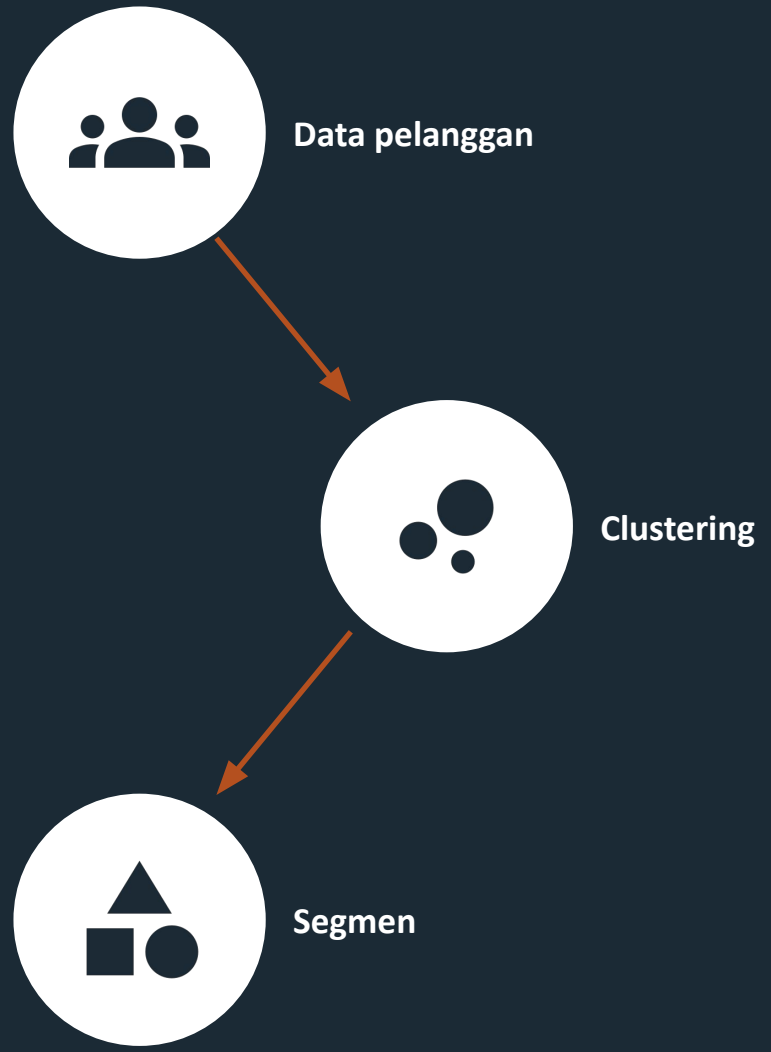
PERTEMUAN 4 · DATA SCIENCE

Unsupervised Learning

Segmentasi pelanggan dengan K-Means



Peta belajar hari ini

1 **Tanpa label**
Supervised vs unsupervised

2 **Mirip = dekat**
Jarak dan scaling

3 **K-Means**
Centroid, kelompokkan, ulangi

4 **Memilih K**
Elbow, silhouette, bisnis

5 **Profil segmen**
Dari angka ke persona

6 **Pakai ulang**
PCA, pelanggan baru, praktik

Hasil akhir hari ini: empat segmen pelanggan yang punya nama, profil, dan ide penawaran untuk kampanye ke-7.

BUSINESS CASE

Satu penawaran untuk semua tidak lagi cukup

Selama ini kita mengirim satu penawaran yang sama ke semua pelanggan, dan hanya sekitar 15% yang merespons. Tolong kelompokkan pelanggan kita menjadi beberapa segmen yang jelas bedanya, beri nama, dan sarankan penawaran untuk tiap segmen.

Manajer marketing RetailKu

Kampanye ke-7

Harus lebih tepat sasaran

Tidak ada kolom “segmen”

Kelompok harus ditemukan dari pola data

Bahan: marketing_fitur.csv

2.026 pelanggan, hasil Pertemuan 3

Waktu dalam cerita: Juli 2014 · Peranmu: data analyst di tim marketing RetailKu (perusahaan fiktif)

KONSEP

Supervised vs unsupervised learning

Supervised learning

Pertemuan 5



Ada jawaban (label) untuk belajar

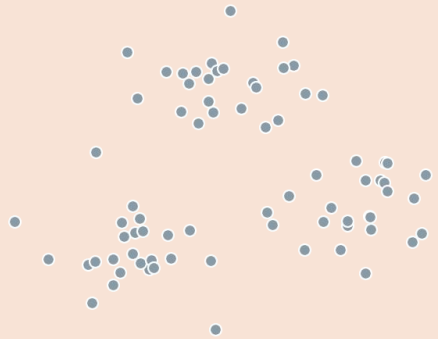
Contoh pertanyaan

Siapa yang akan merespons kampanye?

`Target: kolom Response`

Unsupervised learning

Hari ini



Tidak ada label; mencari struktur sendiri

Contoh pertanyaan

Ada berapa tipe pelanggan, dan seperti apa?

`Target: tidak ada`

Cara menilai berbeda: supervised dibandingkan dengan jawaban; unsupervised dinilai dari apakah kelompoknya kompak, berbeda, dan berguna bagi bisnis.

KONSEP

Empat tugas unsupervised learning



Clustering

Hari ini

Mengelompokkan data yang mirip

Contoh: Segmentasi pelanggan



Reduksi dimensi

Hari ini

Meringkas banyak kolom menjadi sedikit

Contoh: PCA untuk visualisasi



Deteksi anomali

Menemukan data yang tidak biasa

Contoh: Transaksi kartu kredit mencurigakan



Asosiasi

Barang yang sering dibeli bersama

Contoh: Roti → selai (market basket)

Mirip berarti dekat, asal skalanya setara

$$\text{jarak}(A, B) = \sqrt{[\ (x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots\ ]}$$

Siapa yang paling mirip dengan A?

A

Pendapatan 50.000
Anak 0

B

Pendapatan 51.000
Anak 3

C

Pendapatan 60.000
Anak 0

Tanpa scaling

A–B	1.000
A–C	10.000

Paling mirip: B ✗

Setelah standardisasi

A–B	4,02
A–C	0,46

Paling mirip: C ✓



Clustering sepenuhnya bergantung pada jarak. Lupa scaling berarti segmen hanya ditentukan oleh kolom yang angkanya besar (Income), dan mengabaikan anak, diskon, atau kunjungan web.

K-Means dalam empat langkah

1 Mulai

Pilih K titik secara acak sebagai centroid awal

2 Kelompokkan

Setiap pelanggan masuk ke centroid terdekat

3 Perbarui

Centroid pindah ke rata-rata (mean) anggotanya

4 Ulangi

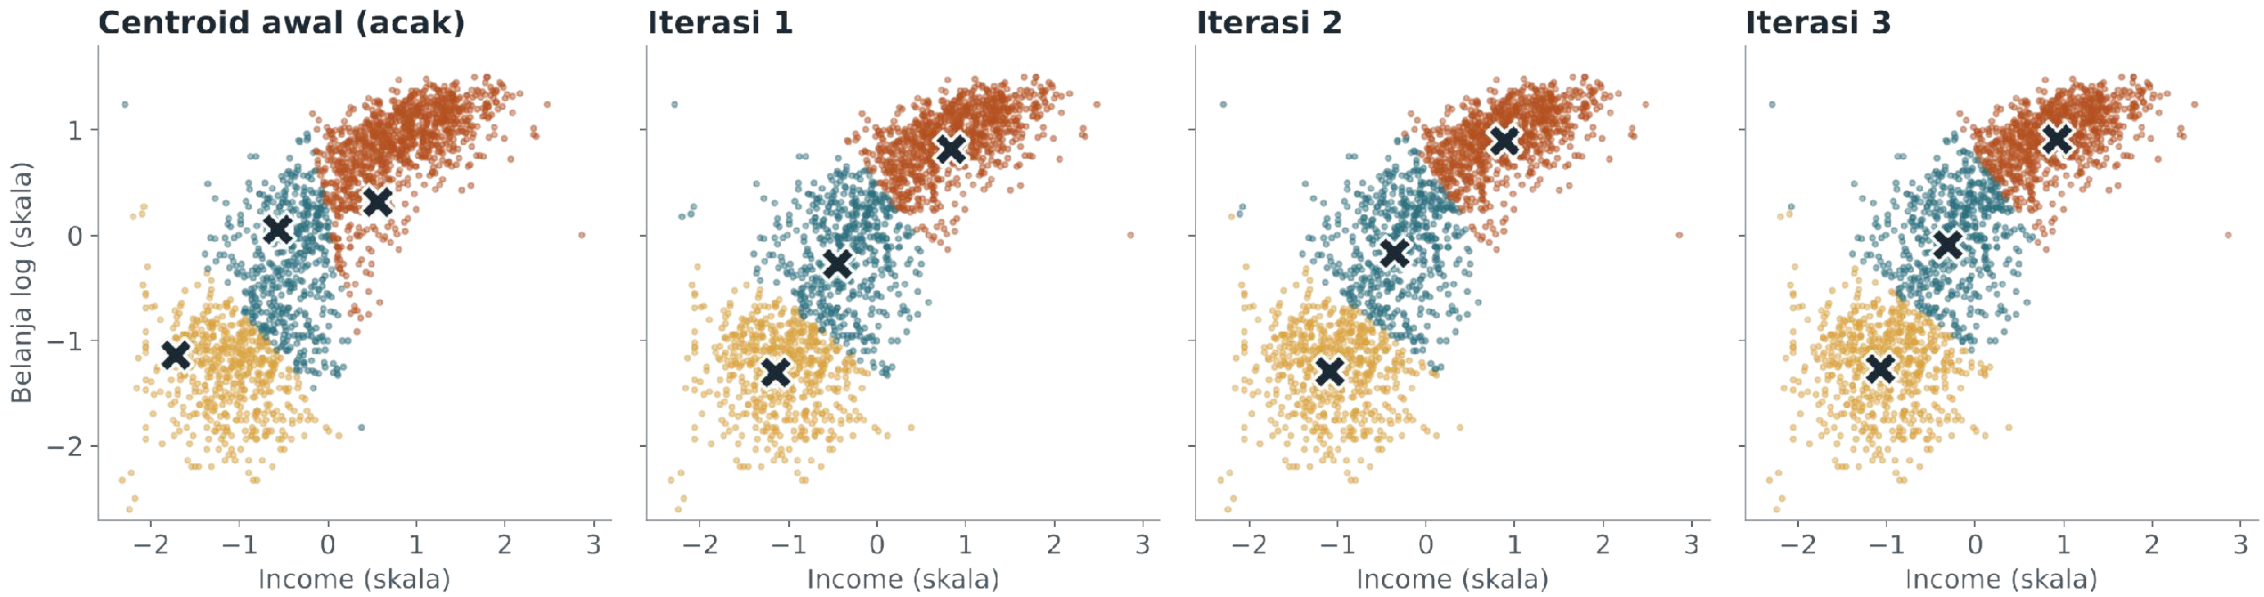
Langkah 2–3 diulang sampai centroid tidak bergerak

ulangi

Dengan scikit-learn, cukup satu baris:

```
KMeans(n_clusters=4, n_init=10, random_state=42).fit(X)
```

Melihat centroid bergerak



Data asli RetailKu, dua fitur (Income dan belanja log, sudah di-scaling), K = 3. Tanda X adalah centroid.

Inertia
Total kuadrat jarak setiap pelanggan ke centroidnya. Makin kecil, makin kompak kelompoknya.

Titik awal berbeda, hasil bisa berbeda
Karena itu K-Means dijalankan berkali-kali (n_init) dan dibuat bisa diulang (random_state).

Empat hal yang perlu diwaspadai



K ditentukan sendiri

Algoritma tidak tahu jumlah segmen terbaik

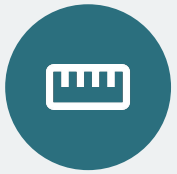
Elbow + silhouette



Peka titik awal

Centroid awal acak bisa memberi hasil berbeda

n_init, random_state



Wajib scaling

Kolom berangka besar mendominasi jarak

StandardScaler

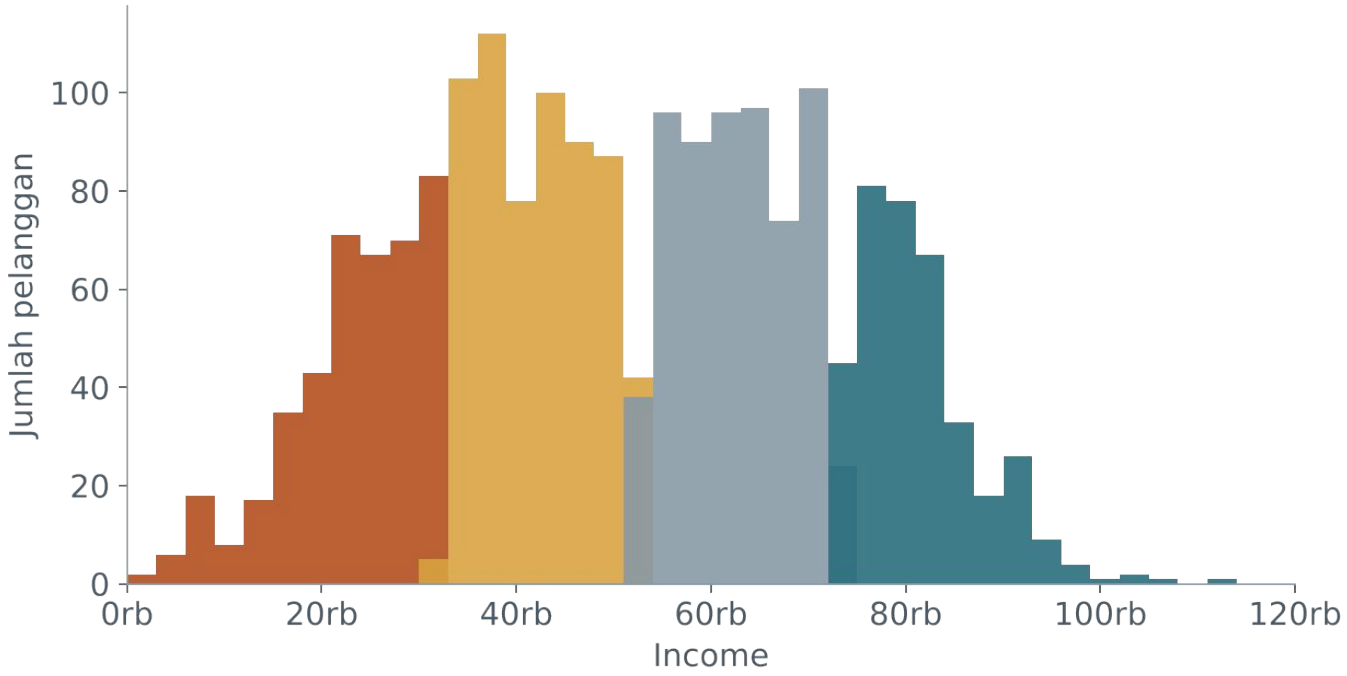


Suka kelompok “bulat”

Kurang cocok untuk bentuk aneh; peka outlier

Cek profil, coba metode lain

Tanpa scaling, segmen hanyalah potongan pendapatan



K-Means (K = 4) pada 6 fitur tanpa scaling. Warna = kelompok.

Rentang angka sangat berbeda
Income: ribuan sampai 160 ribu. Anak: 0–3. Pembelian diskon: 0–15.

Kelompok terpotong rapi
Batas antarkelompok hanya mengikuti Income. Fitur lain hampir tidak berpengaruh.

Pelajaran: scaling dulu, baru clustering. Selalu.

Enam fitur untuk segmentasi

`Income`

Daya beli

`TotalSpend_log`

Nilai pelanggan

`TotalPurchases`

Seberapa sering belanja

`Children`

Tahap hidup, keluarga

`NumDealsPurchases`

Kepekaan terhadap diskon

`NumWebVisitsMonth`

Keterlibatan online

Sengaja tidak dipakai

`ID` hanya nomor

`Response` untuk validasi, bukan pembentuk segmen

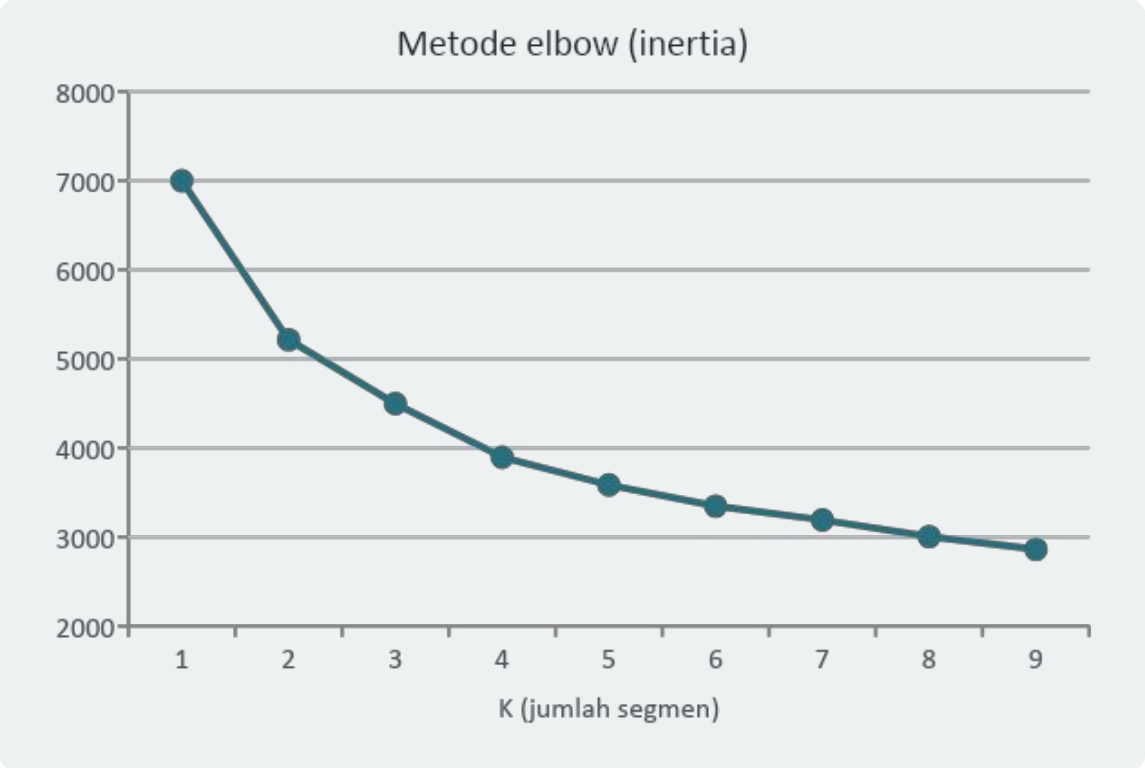
`Marital_Status` kategori; "jarak" Married–Single sulit dimaknai

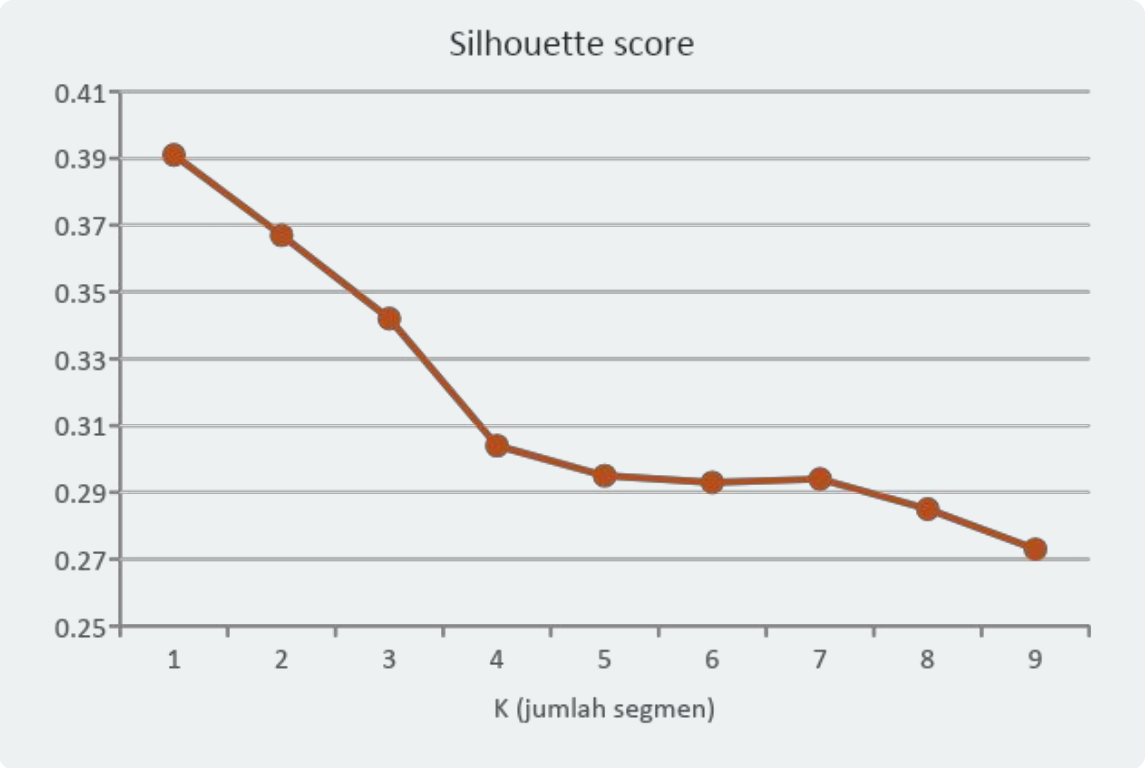
Pipeline yang sama seperti Pertemuan 3, tanpa train-test split karena tidak ada target:

```
Pipeline([("isi_kosong", SimpleImputer(strategy="median")), ("skala", StandardScaler())])
```

Uji fitur yang baik: bisakah tim marketing menindaklanjutinya?

Ada berapa segmen? Elbow dan silhouette





Elbow: inertia selalu turun saat K naik. Cari “siku” saat penurunannya mulai melambat.

Silhouette: −1 sampai 1. Makin tinggi, makin jelas pelanggan terpisah dari kelompok tetangga.

Kenapa kita memilih K = 4?



Elbow

Penurunan inertia mulai melambat di sekitar K = 3–4.



Silhouette

Tertinggi di K = 2 (0,39), tetapi dua segmen terlalu kasar untuk merancang kampanye.



Bisnis

Empat penawaran berbeda masih sanggup dikelola tim marketing. Sembilan tidak.

KEPUTUSAN

K = 4

Silhouette 0,34

Pilihan K selalu gabungan angka dan kebutuhan bisnis.

PROFIL SEGMEN

Empat segmen pelanggan RetailKu

SEGMEN 0

Hemat

825

pelanggan · 41%

Pendapatan median
33.200
Belanja median (2 th)
57

Belanja kecil, sering melihat web tetapi jarang membeli

SEGMEN 1

Pemburu Diskon

205

pelanggan · 10%

Pendapatan median
50.200
Belanja median (2 th)
467

6,6 pembelian diskon, anak paling banyak

SEGMEN 2

Keluarga Mapan

536

pelanggan · 26%

Pendapatan median
60.500
Belanja median (2 th)
765

Belanja rutin dan cukup besar di toko dan web

SEGMEN 3

Premium

460

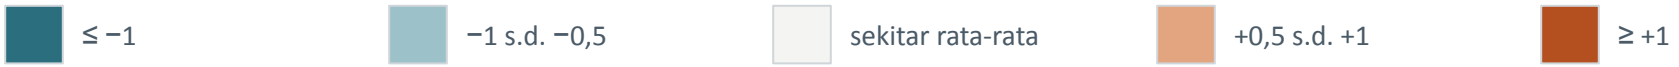
pelanggan · 23%

Pendapatan median
77.400
Belanja median (2 th)
1.335

Hampir tanpa anak, suka katalog, jarang pakai diskon

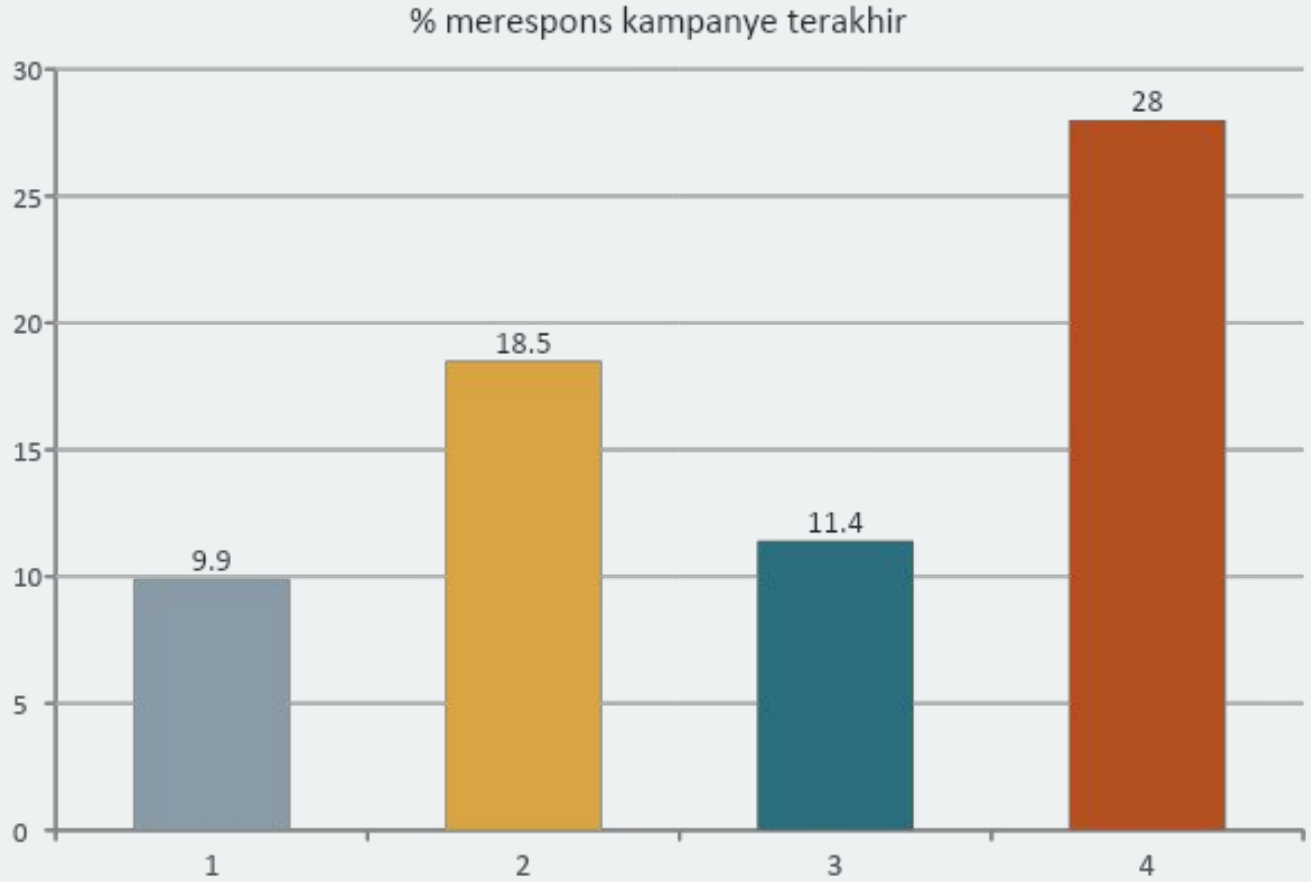
Heatmap profil: siapa menonjol di mana?

Segmen	Pendapatan	Belanja (log)	Jml pembelian	Anak	Beli diskon	Kunjungan web	Beli katalog
0 · Hemat	-0,9	**-1,1**	**-1,0**	+0,4	-0,2	+0,5	-0,8
1 · Pemburu Diskon	-0,1	+0,4	+0,3	+0,9	**+2,2**	+0,8	0,0
2 · Keluarga Mapan	+0,4	+0,6	+0,7	0,0	+0,1	0,0	+0,3
3 · Premium	**+1,2**	**+1,0**	+0,9	**-1,1**	-0,7	**-1,2**	**+1,1**



Cara membaca: angka adalah z-score rata-rata segmen (0 = rata-rata semua pelanggan). Cari 2–3 kotak paling mencolok di tiap baris, lalu jadikan satu kalimat persona.

Segmen berbeda, respons kampanye berbeda



28%

Premium merespons, hampir 3× segmen Hemat

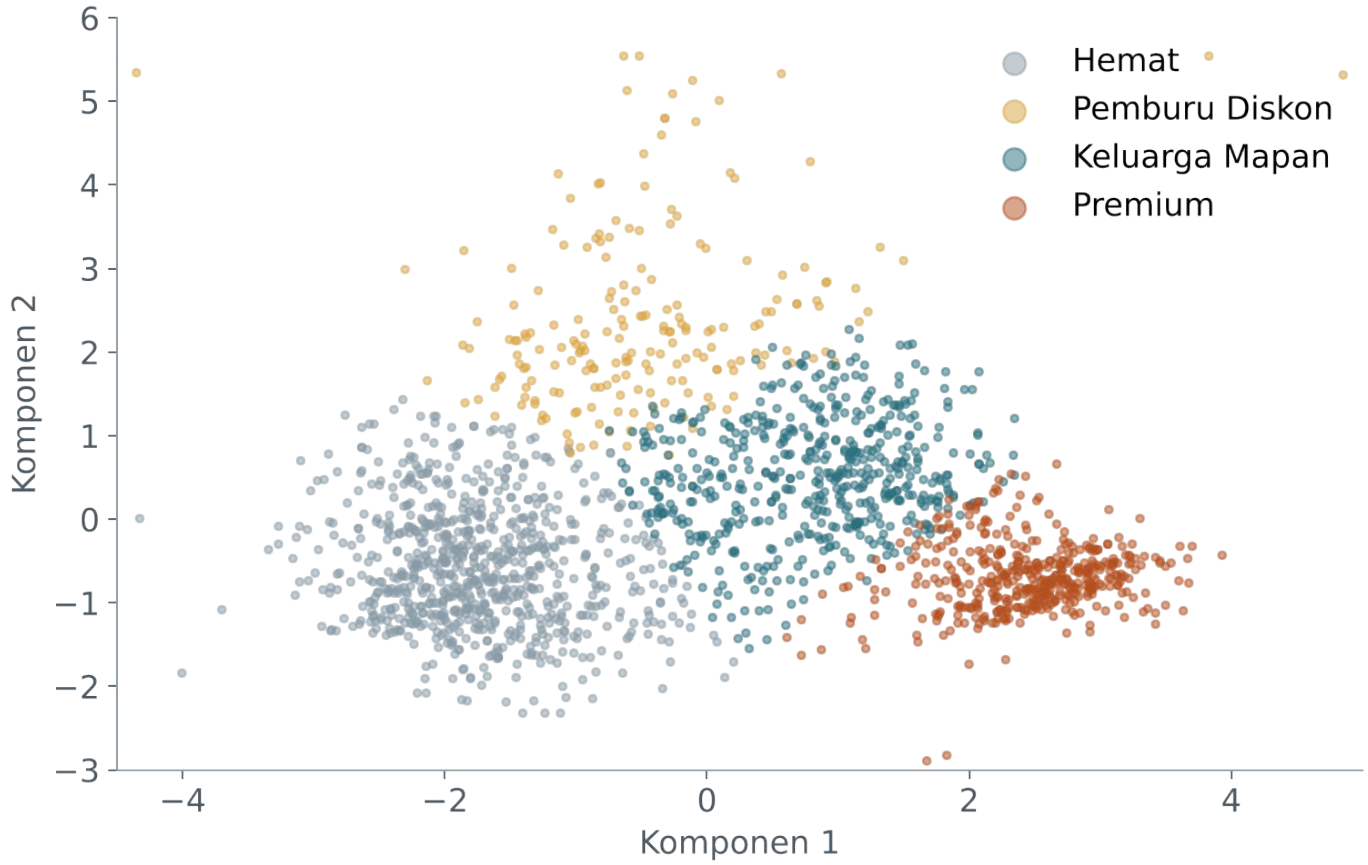
15,3%

Rata-rata semua pelanggan

Response

tidak dipakai untuk membentuk segmen. Bedanya muncul dengan sendirinya: bukti segmen ini berguna

Melihat 6 dimensi dalam 2 dimensi dengan PCA



Komponen 1 · 55% variasi
"Nilai pelanggan": pendapatan, belanja, dan frekuensi belanja

Komponen 2 · 24% variasi
"Diskon dan keluarga": pembelian diskon dan jumlah anak

PCA hanya untuk melihat
Segmentasi tetap memakai 6 fitur asli. Dua komponen menyimpan sekitar 79% variasi.

METODE LAIN

K-Means bukan satu-satunya

K-Means

Dipakai hari ini

Kelompok di sekitar centroid

+ Cepat, mudah dijelaskan
− Harus menentukan K; suka bentuk bulat

Hierarchical

Gabungkan yang paling mirip sedikit demi sedikit (dendrogram)

+ Tidak perlu K di awal; bisa dilihat bertingkat
− Lambat untuk data besar

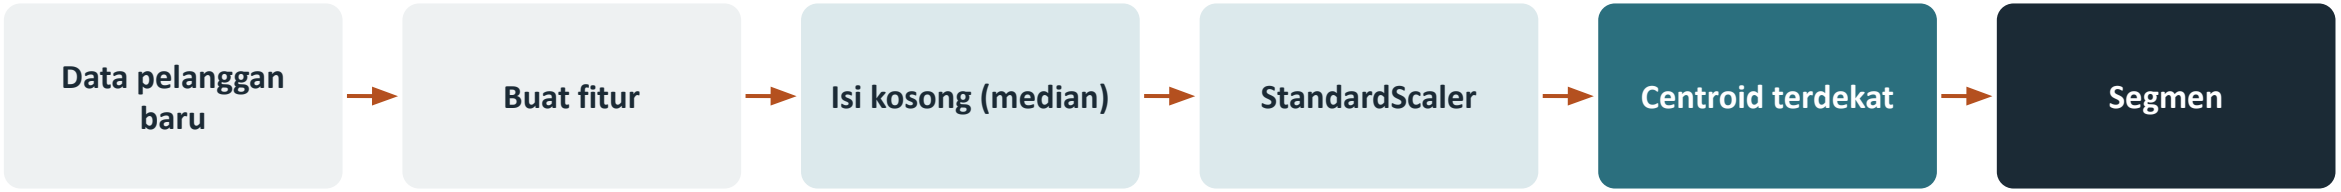
DBSCAN

Kelompok = daerah yang padat

+ Bentuk bebas; menandai outlier
− Parameter sulit dipilih

Di notebook: bagian 11 menampilkan dendrogram 40 pelanggan; Latihan 4–5 membandingkan K-Means dengan hierarchical dan DBSCAN.

Pelanggan baru masuk segmen mana?



dipelajari dari data pelanggan lama (fit), dipakai ulang untuk pelanggan baru (predict)

Bu Rina

Pendapatan 82.000, tanpa anak, belanja besar lewat katalog

→ Premium

Pak Dodi

Pendapatan 29.000, belanja sangat kecil, sering lihat web

→ Hemat

Mbak Sari

Pendapatan kosong, 3 anak, 8 pembelian diskon

→ Pemburu Diskon

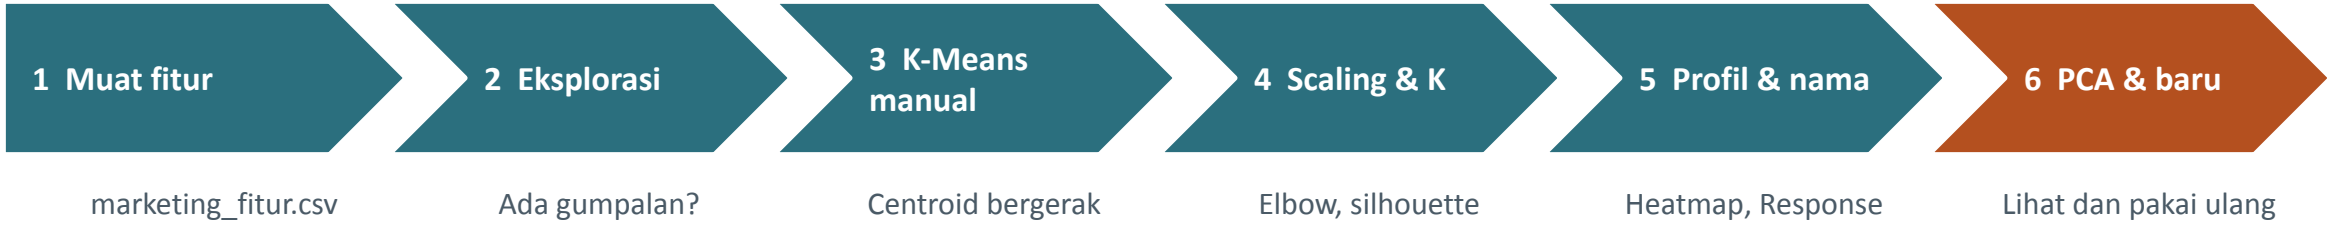
```
model_segmen.predict(fitur_baru[FITUR_SEGMEN])
```

Dari segmen ke kampanye ke-7

SEGMEN	PENAWARAN YANG COCOK	KANAL
Premium	Produk eksklusif (wine, daging premium), bukan diskon	Katalog
Keluarga Mapan	?	?
Pemburu Diskon	?	?
Hemat	?	?

Diskusi: isi tiga baris lainnya dengan melihat heatmap, grafik respons, dan porsi kanal. Jawabanmu menjadi bahan tugas.

Alur praktik di Google Colab



TIGA ATURAN SELAMA PRAKTIK

- Scaling dulu, baru clustering
- Response hanya untuk validasi, bukan pembentuk segmen
- Beri nama segmen yang dimengerti tim marketing

Rangkuman

Tanpa label

Unsupervised learning mencari struktur sendiri, tanpa kunci jawaban

Scaling wajib

Jarak menentukan segmen; kolom berangka besar tidak boleh mendominasi

K = angka + bisnis

Elbow dan silhouette membantu; kebutuhan tim marketing memutuskan

Segmen harus bisa dipakai

Profil, nama, validasi dengan Response, lalu tindakan