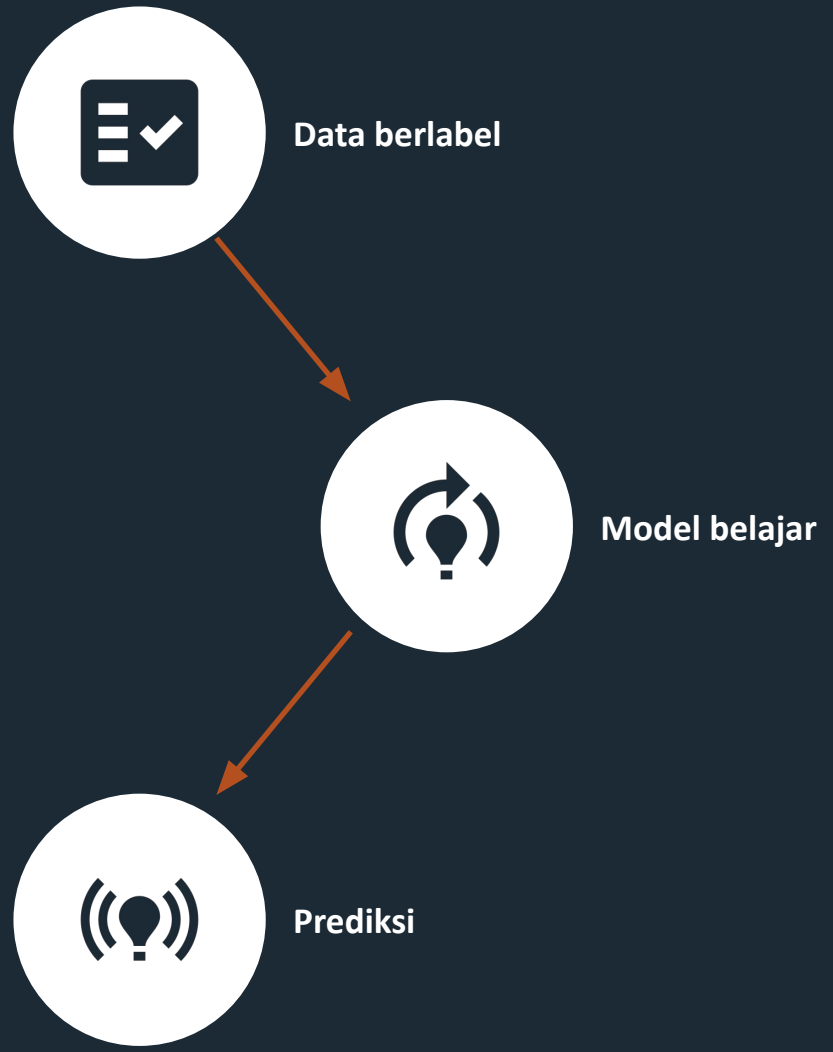
PERTEMUAN 5 · DATA SCIENCE

Classification & Regression

Memprediksi respons kampanye dan potensi belanja pelanggan



Peta belajar hari ini

1 **Ada jawaban**
Supervised, klasifikasi vs regresi

2 **Model malas**
Baseline dan akurasi yang menipu

3 **Empat model**
LogReg, pohon, KNN, hutan

4 **Overfitting**
Menghafal vs memahami

5 **Membaca model**
Koefisien, aturan, peluang

6 **Regresi**
Potensi belanja, MAE, R^2

Hasil akhir hari ini: model yang memilih siapa dikirimi penawaran kampanye ke-7, dan model yang memperkirakan potensi belanja pelanggan baru.

BUSINESS CASE

Dua pertanyaan dari manajer marketing

Anggaran kampanye ke-7 hanya cukup untuk sebagian pelanggan. Beri tahu saya siapa yang kemungkinan besar merespons. Lalu, bisakah kita memperkirakan nilai belanja pelanggan yang baru mendaftar?

Manajer marketing RetailKu

Pertanyaan 1 · Klasifikasi

Apakah pelanggan akan merespons? Target: Response

Pertanyaan 2 · Regresi

Berapa potensi belanjanya? Target: TotalSpend

Bahan: marketing_segmen.csv

2.026 pelanggan, hasil Pertemuan 4

Waktu dalam cerita: Juli 2014 · Peranmu: data analyst di tim marketing RetailKu (perusahaan fiktif)

KONSEP

Supervised learning: belajar dari contoh berjawaban



Pertemuan 4 · unsupervised

Tidak ada jawaban. Model mencari kelompok sendiri.

```
KMeans().fit(X)
```

Pertemuan 5 · supervised

Ada jawaban (y). Model belajar menebak jawaban itu.

```
model.fit(X_train, y_train)
```

Aturan dari Pertemuan 3 tetap berlaku: split dulu, fit persiapan dan model hanya pada data latih.

KONSEP

Klasifikasi atau regresi? Lihat targetnya

Klasifikasi

Target berupa kategori

15,3%

pelanggan merespons kampanye terakhir (Response = 1)

Pertanyaan: Apakah pelanggan ini akan merespons?

`LogisticRegression · DecisionTreeClassifier · KNeighborsClassifier · RandomForestClassifier`

Ukuran: akurasi, confusion matrix

Regresi

Target berupa angka

607

rata-rata TotalSpend dua tahun (median 397)

Pertanyaan: Berapa total belanja pelanggan ini?

`LinearRegression · DecisionTreeRegressor · RandomForestRegressor`

Ukuran: MAE, R^2

BASELINE

Model malas: 85% akurat, tapi tidak berguna

```
DummyClassifier(strategy="most_frequent")
```

Selalu menebak “tidak merespons” untuk semua pelanggan.

84,7%

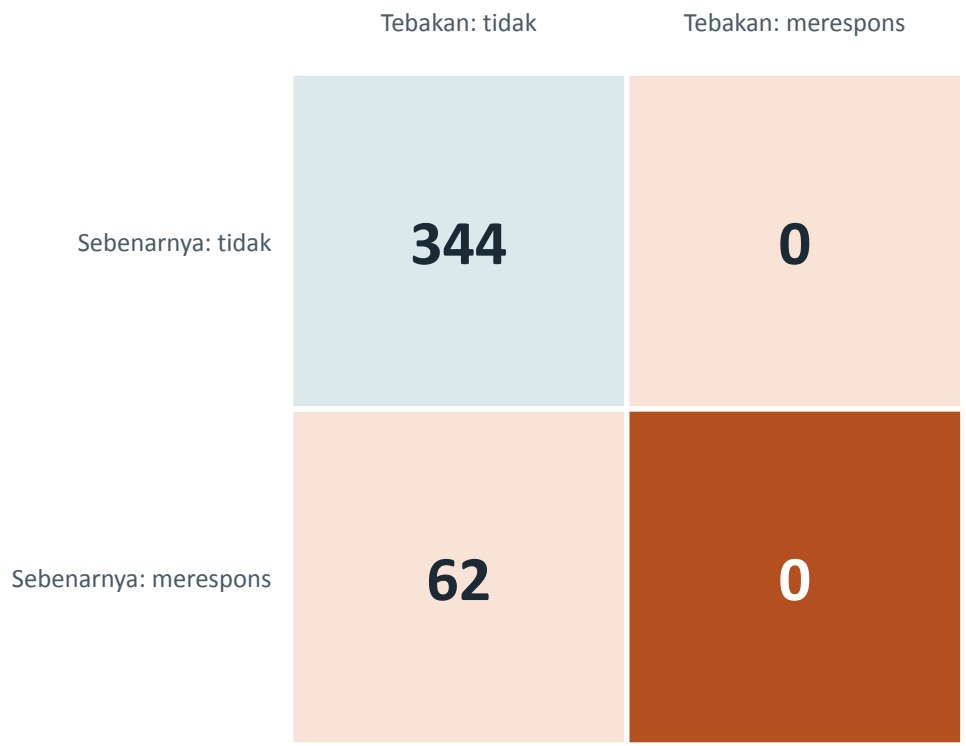
akurasi di data uji

0 / 62

responden tertangkap

Akurasi tinggi hanya karena 85% pelanggan memang tidak merespons.

Confusion matrix model malas (406 pelanggan uji)



Baseline = batas bawah. Model yang kita buat harus mengalahkannya dengan cara yang berarti bagi bisnis.

CONFUSION MATRIX

Empat kotak di balik akurasi

	Ditebak tidak merespons	Ditebak merespons
Sebenarnya tidak	**332** **Benar diabaikan** Tidak merespons, tidak dikirimi	**12** **Penawaran terbuang** Dikirimi, tapi tidak merespons
Sebenarnya merespons	**38** **Responden terlewat** Akan merespons, tapi tidak dikirimi	**24** **Responden tertangkap** Akan merespons, dan dikirimi

LOGISTIC REGRESSION

Akurasi

87,7%

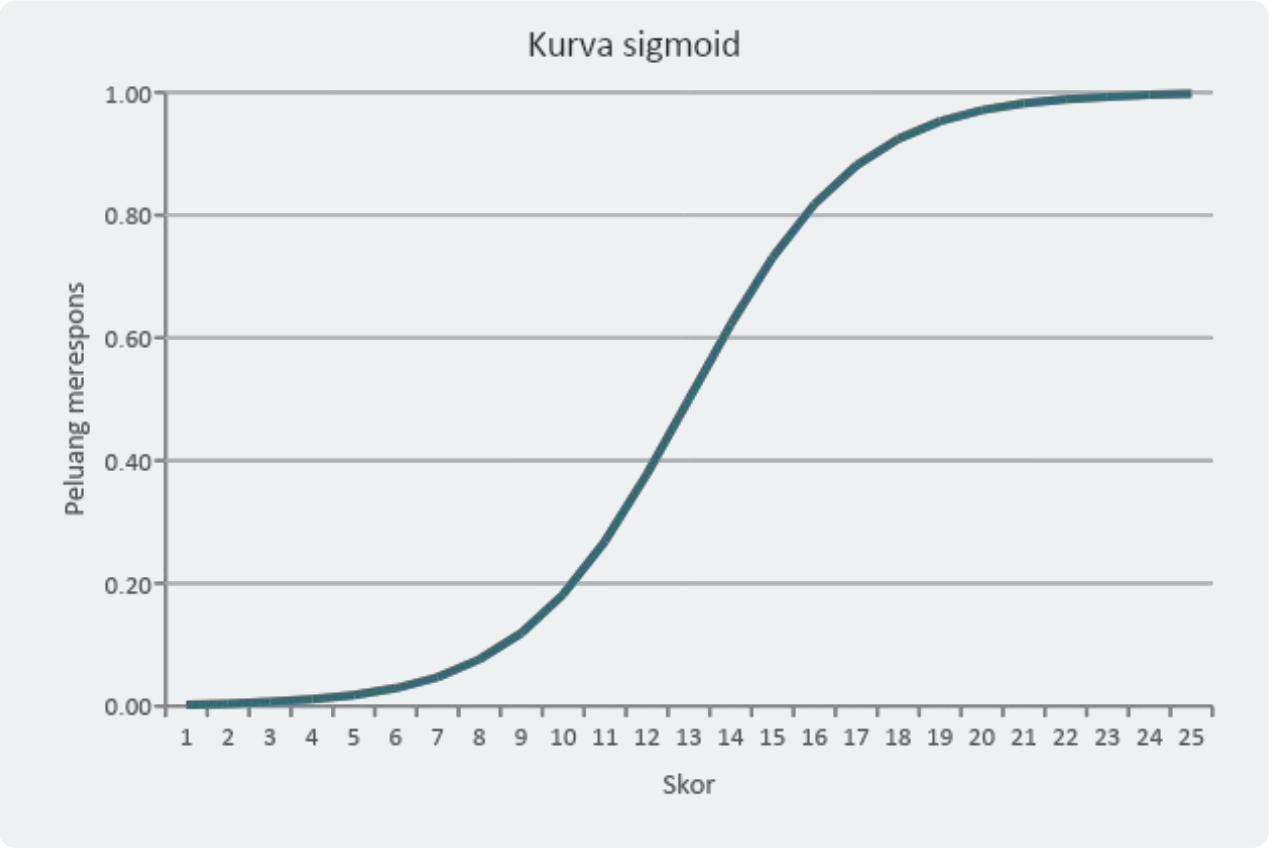
Responden tertangkap

24 dari 62 (39%)

Naik 3 poin akurasi, tapi dari 0 menjadi 24 responden.

Nama resminya (true/false positive/negative, precision, recall) dibahas di Pertemuan 6.

Logistic Regression: dari skor menjadi peluang



1 **Hitung skor**

`skor = b0 + b1·x1 + b2·x2 + …`

2 **Ubah jadi peluang**

Sigmoid memeras skor ke 0 sampai 1

3 **Putuskan**

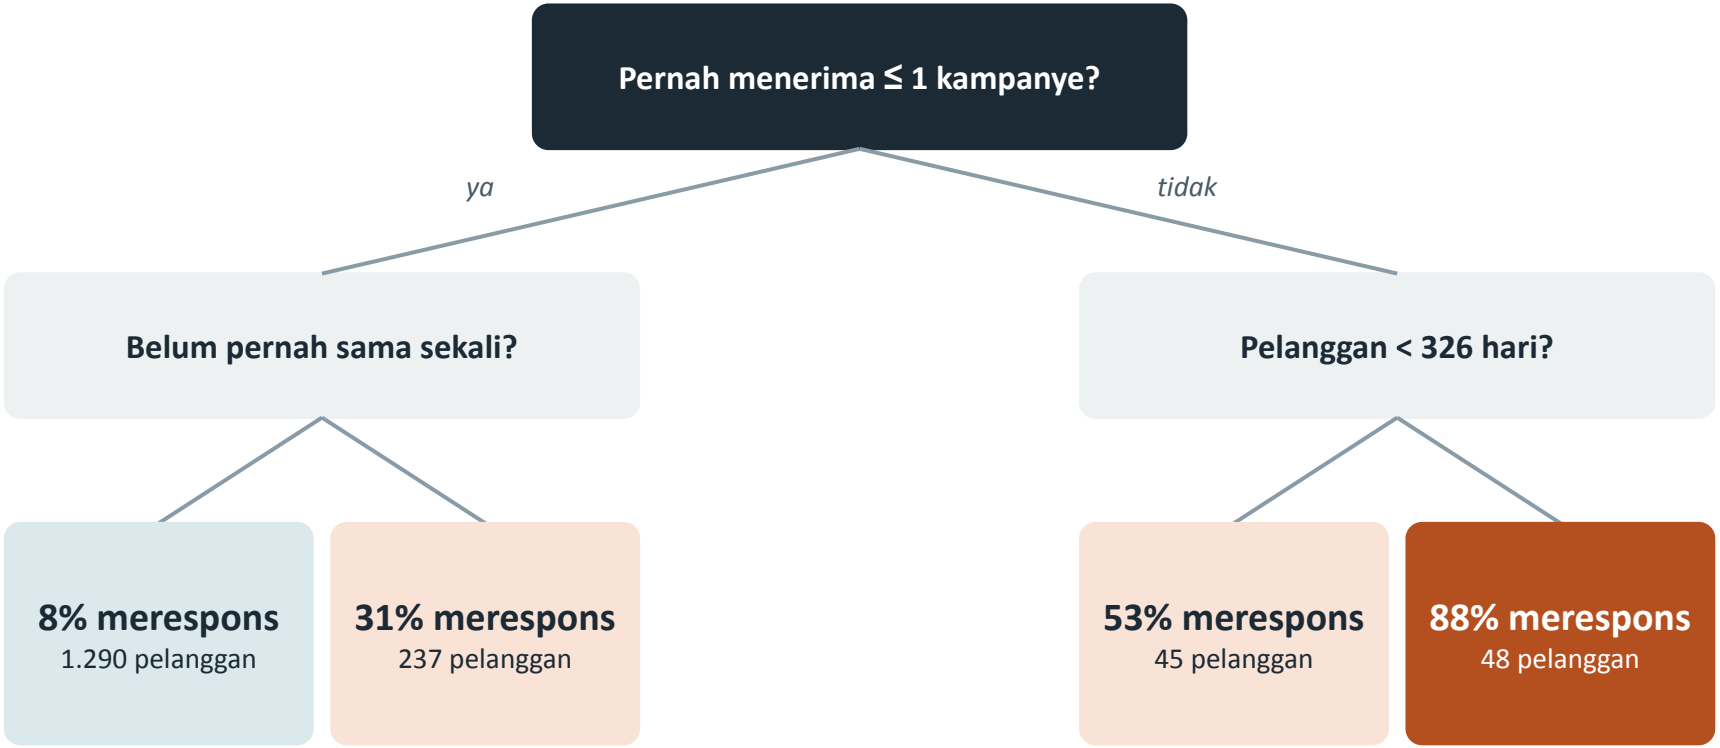
Peluang ≥ 0,5 ⟶ tebak “merespons”

Peluang lebih berguna daripada 0/1: bisa untuk mengurutkan prioritas.

```
LogisticRegression(max_iter=1000)    ·    model.predict_proba(X_test)[:, 1]
```

MODEL 2

Decision Tree: aturan “jika … maka …”



Dua tingkat pertama pohon (max_depth=3) dari data latih RetailKu

Mudah dijelaskan
Aturannya bisa dibaca tim marketing

Tanpa scaling
Membandingkan dengan batas, bukan jarak

Mudah overfitting
Pohon dalam menghafal data latih

Contoh aturan: jika pernah menerima ≥ 2 kampanye dan sudah lama jadi pelanggan, 88% merespons.

KNN dan Random Forest

K-Nearest Neighbors

Tanya tetangga terdekat

Cari K pelanggan paling mirip di data latih, lalu ikuti suara terbanyak. Memakai jarak, sama seperti Pertemuan 4.

+ Ide sederhana, tanpa rumus
− Wajib scaling; lambat untuk data besar

```
KNeighborsClassifier(n_neighbors=5)
```

Random Forest

Banyak pohon, satu suara

Ratusan pohon, masing-masing dilatih dengan sampel data dan fitur yang sedikit berbeda. Hasil akhir: suara terbanyak.

+ Biasanya stabil dan kuat
− Sulit dibaca; bisa menghafal data latih

```
RandomForestClassifier(n_estimators=300)
```

Scaling: perlu untuk Logistic Regression dan KNN; tidak perlu untuk Decision Tree dan Random Forest.

PERBANDINGAN

Akurasi mirip, responden tertangkap berbeda jauh

Model	Akurasi uji	Responden tertangkap	Akurasi latih
Model malas	84,7%	**0 dari 62 (0%)**	84,7%
Logistic Regression	87,7%	**24 dari 62 (39%)**	88,8%
Decision Tree (depth 3)	86,0%	**22 dari 62 (36%)**	88,2%
KNN (k=5)	86,0%	**18 dari 62 (29%)**	90,0%
Random Forest	86,5%	**20 dari 62 (32%)**	**99,5%**

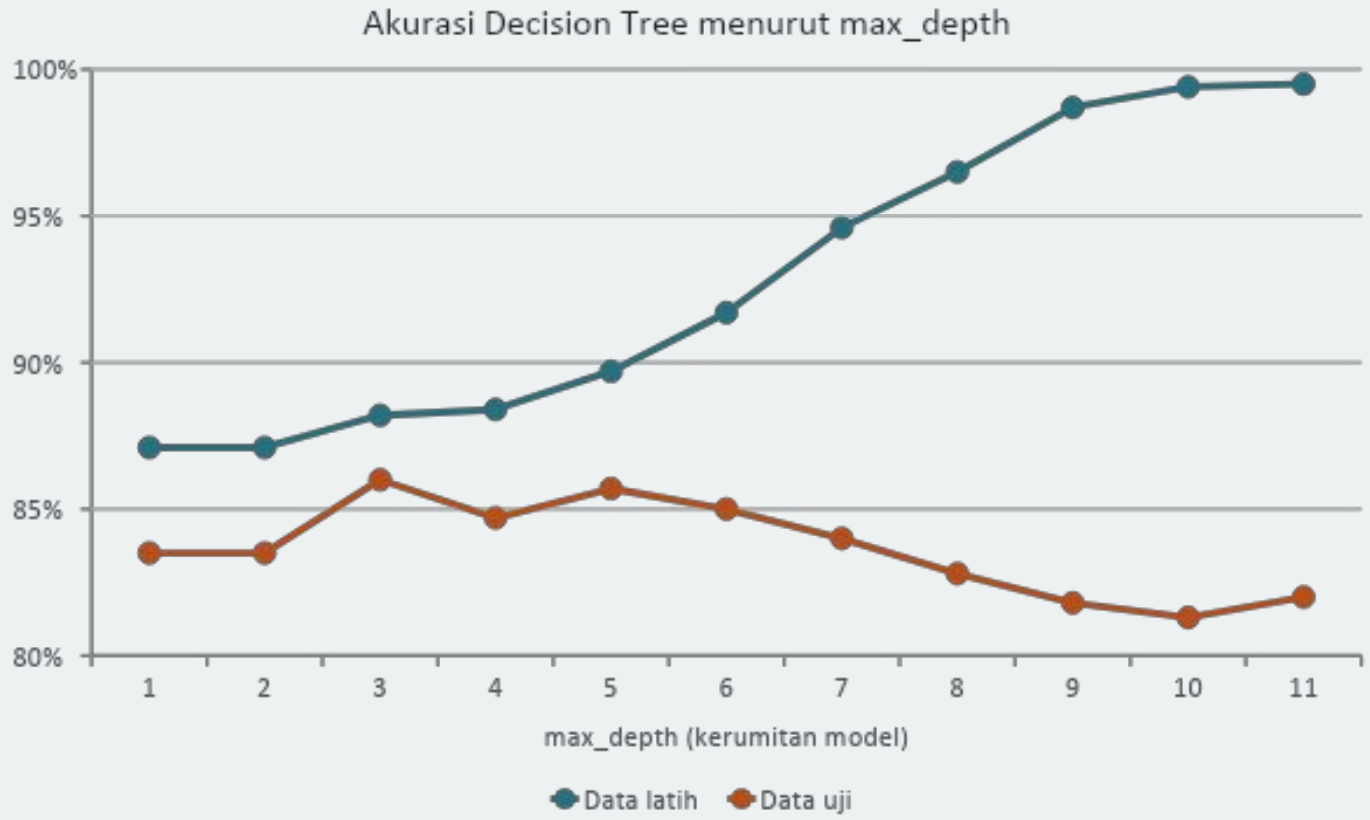
Data uji: 406 pelanggan, 62 di antaranya merespons. Semua model memakai fitur dan split yang sama (80/20, stratify, random_state=42).

Akurasi: 84,7–87,7%
Selisihnya hanya 3 poin. Akurasi tidak membedakan model dengan jelas.

Tertangkap: 0–39%
Inilah beda yang terasa bagi tim marketing.

Random Forest 99,5% di latih
Tapi 86,5% di uji. Tanda menghafal: lihat slide berikutnya.

Menghafal bukan memahami



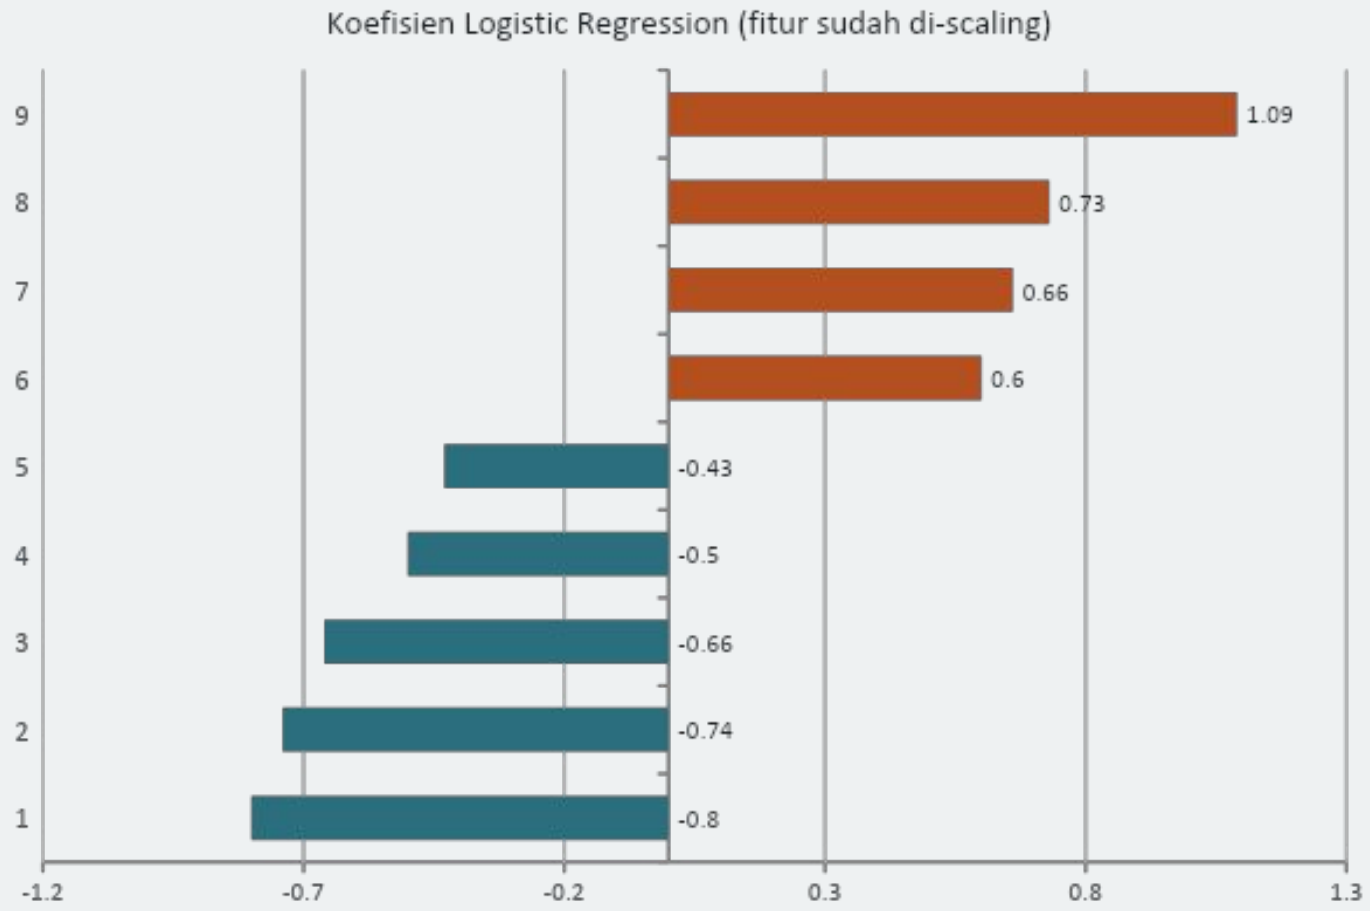
Underfitting
Latih rendah, uji rendah
Model terlalu sederhana

Pas (depth ±3)
Latih 88%, uji 86%
Menangkap pola umum

Overfitting (depth 20)
Latih 99,5%, uji 82%
Menghafal kebetulan di data latih

Seperti mahasiswa yang menghafal kunci jawaban latihan: nilai latihan sempurna, nilai ujian turun. Memilih model yang adil memakai cross-validation (Pertemuan 7).

Apa yang menaikkan peluang merespons?



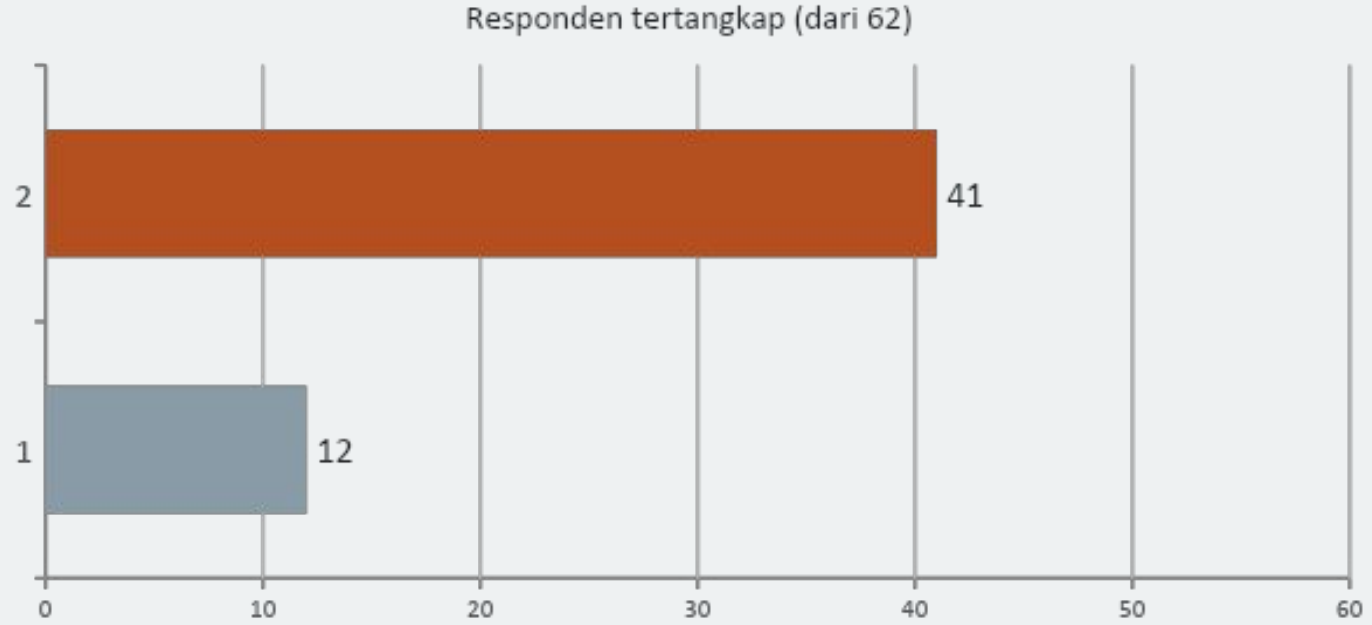
Menaikkan peluang
Pernah menerima kampanye sebelumnya, sudah lama jadi pelanggan, belanja besar, berstatus single

Menurunkan peluang
Lama tidak berbelanja (Recency tinggi), berpasangan, punya anak

Hati-hati
Koefisien menunjukkan hubungan, bukan sebab-akibat. Dibandingkan hanya karena semua fitur sudah di-scaling.

Anggaran terbatas? Urutkan berdasarkan peluang

Penawaran dikirim ke 20% pelanggan data uji (81 dari 406)



66% responden tertangkap hanya dengan 20% penawaran

51% tingkat respons kelompok yang dipilih model (rata-rata 15%)

±3× lebih banyak responden daripada pilih acak

Pertemuan 7: berapa persen yang sebaiknya dikirimi, jika setiap penawaran ada biayanya dan setiap respons ada untungnya?

Pelanggan baru: hanya profilnya yang diketahui

Boleh dipakai: profil saat mendaftar

`Income`
Pendapatan

`Age`
Umur

`Children`
Jumlah anak

`Tenure_days`
Lama berlangganan

`Education`
Pendidikan

`Marital_Status`
Status pernikahan

Tidak boleh: dihitung dari target

`MntWines, MntMeatProducts, …`
TotalSpend adalah jumlah kolom-kolom ini

`TotalSpend_log, AvgSpendPerPurchase`
Diturunkan langsung dari TotalSpend

`Segmen (Pertemuan 4)`
Dibentuk memakai TotalSpend_log

Kebocoran bentuk 1 dari Pertemuan 3: model terlihat hebat karena hanya menyalin jawaban. Lagi pula, pelanggan baru belum punya riwayat belanja.

Dua ukuran untuk model regresi

MAE

Mean Absolute Error

Rata-rata selisih tebakan dengan nilai sebenarnya, dalam satuan target.

MAE 186 → rata-rata tebakan meleset sekitar 186 dari belanja sebenarnya.

Makin kecil makin baik

```
mean_absolute_error(y_test, tebakan)
```

R^2

Koefisien determinasi

Seberapa jauh model lebih baik daripada sekadar menebak rata-rata.

R^2 0 = sama saja dengan rata-rata. R^2 1 = sempurna. R^2 0,81 = cukup baik.

Makin dekat ke 1 makin baik

```
r2_score(y_test, tebakan)
```

Baseline regresi: selalu menebak rata-rata data latih (606). MAE baseline = 524, R^2 = 0. RMSE dan perbandingan lebih dalam dibahas di Pertemuan 6.

Linear Regression: setiap fitur punya “harga”

```
TotalSpend ≈ b0 + b1·Income + b2·Age + b3·Children + b4·Tenure_days + …
```



+10.000 pendapatan

+190



+1 anak

−210



+1 tahun berlangganan

+185



+1 tahun umur

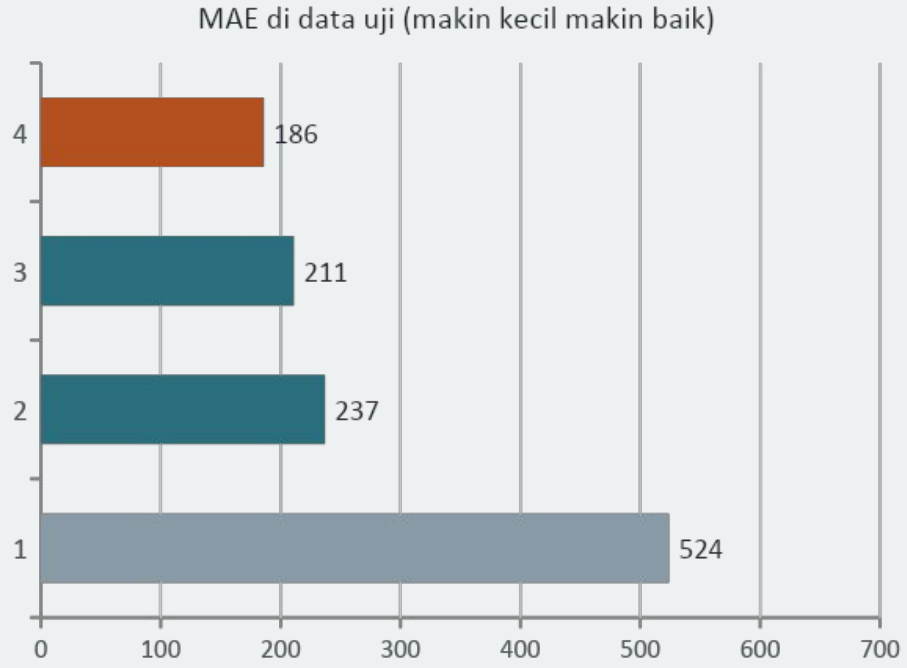
≈ +1

Perubahan perkiraan TotalSpend (2 tahun) jika satu fitur naik, fitur lain tetap. Model dilatih dengan data latih RetailKu.

Cocok dengan Pertemuan 4: segmen Premium hampir tanpa anak dan berpendapatan tinggi.

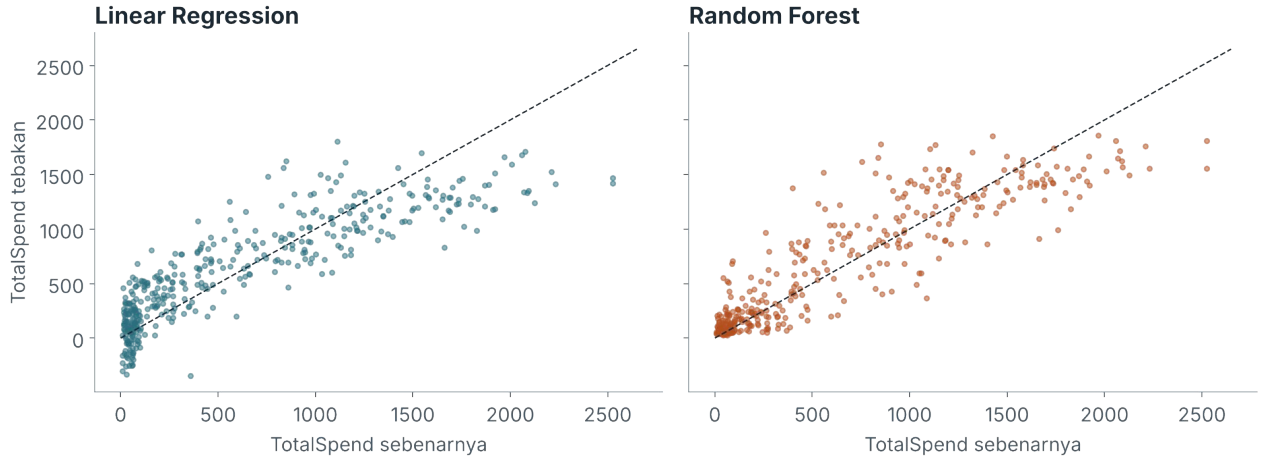
Kelemahan: garis lurus bisa menebak belanja negatif untuk pelanggan berpendapatan rendah dengan banyak anak.

Model regresi: dari meleset 524 menjadi 186



R^2 di data uji

0,00	0,76	0,76	0,81
Model malas	Linear Regression	Decision Tree (4)	Random Forest



Garis putus-putus = tebakan sempurna. Data uji: 406 pelanggan.

Bacaan untuk tim CRM

Hanya dari profil, Random Forest memperkirakan belanja dua tahun dengan rata-rata meleset ±186. Cukup untuk membedakan pelanggan bernilai tinggi dan rendah, belum cukup untuk angka anggaran yang presisi.

Berapa potensi belanja pelanggan minggu ini?

Bu Rina

Pendapatan 82.000 · 52 tahun · tanpa anak · Master

Linear Regression	Random Forest
1.204	1.270

Sambut serius: calon Premium

Pak Dodi

Pendapatan 29.000 · 33 tahun · 1 anak · Graduation

Linear Regression	Random Forest
−19	34

Potensi kecil

Mbak Sari

Pendapatan kosong · 41 tahun · 3 anak · PhD

Linear Regression	Random Forest
−18	110

Pendapatan diisi median oleh pipeline

Belanja negatif? Garis lurus tidak tahu bahwa belanja minimal 0. Model pohon menebak dari rata-rata pelanggan mirip, jadi tidak pernah negatif.

Alur praktik di Google Colab

1 Muat data	2 Model malas	3 4 model	4 Overfitting	5 Baca model	6 Regresi
marketing_segmen.csv	Baseline, confusion	LogReg, pohon, KNN, hutan	Kurva max_depth	Koefisien, prioritas	MAE, R^2, pelanggan baru

TIGA ATURAN SELAMA PRAKTIK

- Selalu bandingkan dengan model malas
- Fit hanya di data latih; nilai di data uji
- Jangan berhenti di akurasi: lihat confusion matrix

Rangkuman

Supervised learning

Belajar dari contoh berjawaban: fit di data latih, predict untuk data baru

Baseline dulu

Model malas 84,7% akurat tapi 0 responden: akurasi bisa menipu

Waspadai overfitting

Skor latih tinggi dan skor uji rendah berarti model menghafal

Model harus bisa dipakai

Peluang untuk prioritas kampanye; MAE dan R^2 untuk potensi belanja

PENUTUP

Tugas dan pertemuan berikutnya

TUGAS

1. Tabel rekomendasi: model terbaik untuk klasifikasi dan regresi, ukuran yang dipakai, dan hasilnya
2. Memo 4–6 kalimat: model yang direkomendasikan, kenapa akurasi saja tidak cukup, dan berapa responden tertangkap di 20% teratas
3. Kumpulkan notebook yang sudah dijalankan dan file prediksi_response_uji.csv

PERTEMUAN 6

Model Evaluation

Akurasi menipu. Kenalan dengan precision, recall, F1, ROC-AUC, dan RMSE.

